ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA HỆ THỐNG THÔNG TIN

IS403 - PHÂN TÍCH DỮ LIỆU KINH DOANH

ĐỒ ÁN:

PHÂN TÍCH VÀ DỰ BÁO CHẤT LƯỢNG KHÔNG KHÍ (PM2.5) TẠI TP.HCM

Nhóm sinh viên thực hiện:

1. Nguyễn Quang Dũng - 23520335 (Nhóm trưởng)
2. Trần Nguyễn Tiến Đức - 23520322
3. Trần Anh Đức - 23520316
4. Trần Quốc Bảo - 23520143

Giảng viên hướng dẫn:

Dr. Trần Văn Hải Triều

TP. Hồ Chí Minh, 2026

Mục lục

Phân công nhiệm vụ **iii**

1 GIỚI THIỆU BÀI TOÁN **1**
1.1 Tính cấp thiết của đề tài . . . 1
1.1.1 Tính cấp thiết của đề tài . . . 1
1.1.2 Định hướng nghiên cứu . . . 2
1.2 Mục tiêu nghiên cứu . . . 3
1.2.1 Mục tiêu tổng quát: . . . 3
1.2.2 Mục tiêu cụ thể: . . . 3
1.3 Đối tượng và phạm vi nghiên cứu . . . 3
1.3.1 Đối tượng nghiên cứu . . . 3
1.3.2 Phạm vi nghiên cứu . . . 4

2 CƠ SỞ LÝ THUYẾT **5**
2.1 Các yếu tố khí tượng ảnh hưởng đến PM2.5 . . . 5
2.1.1 Dữ liệu Chất lượng không khí (OpenAQ) . . . 5
2.1.2 Dữ liệu Khí tượng (Open-Meteo API) . . . 5
2.2 Ứng dụng học máy trong dự báo chất lượng không khí . . . 6
2.2.1 Nhóm mô hình thống kê (ARIMA, ARIMAX, SARIMA, SARIMAX) 6
2.2.2 Nhóm mô hình dựa trên cấu trúc cây (Random Forest, Gradient Boosting) . . . 6
2.2.3 Nhóm mạng nơ-ron hồi quy (LSTM, GRU) . . . 7

3 DỮ LIỆU VÀ QUY TRÌNH PHÂN TÍCH **8**
3.1 Dữ liệu thô (Raw Data) . . . 8
3.1.1 Dữ liệu nồng độ bụi từ OpenAQ . . . 8
3.1.2 Dữ liệu khí tượng từ Open-Meteo API . . . 8
3.2 Làm sạch dữ liệu cơ bản (Basic Cleaning) . . . 9
3.3 Phân tích khám phá (EDA - Train Only) . . . 10
3.3.1 Phân tích đơn biến (Univariate Analysis) . . . 10
3.3.2 Phân tích nhị biến (Bivariate Analysis) . . . 16
3.3.3 Phân tích đa biến (Multivariate Analysis) . . . 21
3.3.4 Kết luận EDA . . . 24
3.4 Tiền xử lý dữ liệu (Preprocessing) . . . 25
3.4.1 Kỹ thuật đặc trưng (Feature Engineering) . . . 25
3.4.2 Phân chia dữ liệu (Train/Val/Test Split) . . . 26
3.4.3 Phân tích và Lựa chọn đặc trưng (Feature Selection) . . . 27
3.4.4 Biến đổi và Chuẩn hóa dữ liệu (Scaling & Transformation) . . . 29

4 HUẤN LUYỆN VÀ TỐI ƯU HÓA MÔ HÌNH (MODEL TRAINING) 31
4.1 Thiết lập mô hình cơ sở (Baseline Models) 31
4.1.1 Nhóm mô hình học máy dạng cây (Tree-based Models) 31
4.1.2 Nhóm mô hình thống kê (Statistical Models) 32
4.1.3 Nhóm mô hình học sâu (Deep Learning Models) 33
4.2 Chiến lược Tối ưu hóa Siêu tham số (Tuning Strategy) 35
4.2.1 Tối ưu hóa nhóm mô hình cây (Tree-based Models) 35
4.2.2 Tối ưu hóa mô hình thống kê (Statistical Models Tuning) 36
4.2.3 Tối ưu hóa nhóm mô hình học sâu (Deep Learning Models Tuning) 37

5 ĐÁNH GIÁ VÀ TỐI ƯU HÓA KẾT QUẢ (EVALUATION & OPTIMIZATION) 38
5.1 Kết quả thực nghiệm sau tối ưu hóa 38
5.1.1 Nhóm mô hình cây (Tree-based Models) 38
5.1.2 Nhóm mô hình thống kê (Statistical Models) 40
5.1.3 Nhóm mô hình học sâu (Deep Learning Models) 41
5.2 Đề xuất mô hình kết hợp (Hybrid Model) 42
5.2.1 Kiến trúc mô hình SARIMAX-GRU 42
5.2.2 Hiệu năng mô hình Hybrid 42
5.3 Đối sánh tổng thể và Lựa chọn mô hình tối ưu 43
5.3.1 Phân tích và Thảo luận 43
5.3.2 Kết luận lựa chọn 44
5.4 Trực quan hóa kết quả dự báo (Visual Inspection) 44
5.4.1 So sánh trực quan các chỉ số lỗi 44
5.5 Giải thích mô hình và Phân tích sâu (Interpretation) 44
5.5.1 Vai trò chủ đạo của tính mùa vụ (Seasonality) 45
5.5.2 Tính bền vững và chu kỳ của ô nhiễm 45
5.5.3 Ảnh hưởng của các yếu tố khí tượng 46

6 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 47
6.1 Kết luận chung 47
6.2 Hạn chế của đề tài 48
6.3 Hướng phát triển tương lai 48

Tài liệu tham khảo 50

PHÂN CÔNG NHIỆM VỤ

STT	Họ và Tên	Nhiệm vụ đảm nhiệm
1	Nguyễn Quang Dũng	Nhóm trưởng, crawl dữ liệu, làm sạch dữ liệu, thêm insights cho EDA, kỹ thuật đặc trưng, nhóm mô hình thống kê, nhóm mô hình học sâu, mô hình kết hợp, viết báo cáo.
2	Trần Nguyễn Tiến Đức	Phân chia dữ liệu, lựa chọn đặc trưng, biến đổi và chuẩn hóa dữ liệu, nhóm mô hình dạng cây, tạo mạch dữ liệu real-time + demo.
3	Trần Anh Đức	EDA, nhóm mô hình thống kê, nhóm mô hình học sâu, thực hiện code rscript, slide thuyết trình.
4	Trần Quốc Bảo	EDA, nhóm mô hình dạng cây, thực hiện code rscript, viết báo cáo, slide thuyết trình.

Chapter 1

GIỚI THIỆU BÀI TOÁN

1.1 Tính cấp thiết của đề tài

1.1.1 Tính cấp thiết của đề tài

Trong bối cảnh đô thị hóa và công nghiệp hóa diễn ra với tốc độ nhanh chóng, Thành phố Hồ Chí Minh (TP.HCM) đang đối mặt với những thách thức mang tính hệ thống đối với công tác quản lý chất lượng môi trường không khí. Sự gia tăng mật độ dân cư tập trung, đi cùng với sự mở rộng các hạ tầng giao thông và hoạt động sản xuất công nghiệp, đã trực tiếp làm biến đổi cấu trúc nồng độ các chất gây ô nhiễm trong khí quyển. Trong số các tác nhân ô nhiễm dạng hạt, bụi mịn PM2.5 (Particulate Matter có đường kính khí động học ≤ 2.5 μm) được xác định là chỉ số rủi ro quan yếu nhất [10], với nồng độ thường xuyên ghi nhận mức vượt ngưỡng an toàn theo Quy chuẩn Kỹ thuật Quốc gia (QCVN) và các khuyến nghị sức khỏe từ Tổ chức Y tế Thế giới (WHO). Về phương diện y sinh và độc học, bụi mịn PM2.5 sở hữu khả năng xuyên thấu sâu vào cấu trúc phế nang và thẩm thấu qua hàng rào máu – khí để đi vào hệ tuần hoàn. Quá trình này không chỉ gây ra các phản ứng viêm cấp tính mà còn là tác nhân gốc rễ của các bệnh lý mãn tính liên quan đến hệ hô hấp, tim mạch và các dạng bệnh lý ác tính, dẫn đến sự gia tăng tỷ lệ tử vong sớm trong cộng đồng [7]. Do đó, việc thiết lập cơ chế dự báo nồng độ PM2.5 dựa trên sự kết hợp của các phương pháp phân tích đa chiều đã trở thành một yêu cầu thiết yếu trong các chiến lược bảo vệ sức khỏe cộng đồng và phát triển an sinh xã hội bền vững.

Sự bách thiết của nghiên cứu này còn xuất phát từ những hạn chế kỹ thuật trong công tác quản lý và giám sát chất lượng không khí hiện nay tại địa bàn thành phố:

- **Hạn chế trong khả năng dự báo của hệ thống hiện hữu:** Phần lớn các hạ tầng quan trắc tại TP.HCM hiện nay tập trung vào việc thu thập và hiển thị dữ liệu thực tế tại thời điểm đo đạc. Tuy nhiên, các thông tin này chỉ mang tính chất mô tả trạng thái đã xảy ra mà thiếu đi khả năng dự báo các biến động trong tương lai ngắn hạn. Sự thiếu hụt các mô hình dự báo khiến cả cơ quan quản lý và người dân rơi vào trạng thái thụ động, hạn chế khả năng triển khai các biện pháp can thiệp sớm hoặc điều chỉnh hoạt động để giảm thiểu rủi ro tiếp xúc.

- **Sự chi phối phức tạp của các yếu tố khí tượng:** Nồng độ $PM_{2.5}$ không chỉ phụ thuộc vào nguồn phát thải tại chỗ mà còn chịu sự tác động bởi các tương tác phi tuyến tính của các yếu tố khí tượng vi mô như nhiệt độ, độ ẩm, tốc độ gió và độ cao tầng biên khí quyển (Boundary Layer Height). Đặc biệt, hiện tượng nghịch nhiệt

thường xuyên xảy ra tại khu vực phía Nam đóng vai trò là tác nhân ngăn cản sự khuếch tán, dẫn đến tích tụ bụi mịn cục bộ với cường độ cao.

Từ thực tế trên, việc ứng dụng các kỹ thuật tiên tiến trong Khoa học Dữ liệu và Học sâu (Deep Learning) để xây dựng mô hình dự báo nồng độ $PM_{2.5}$ trong khung thời gian 24 giờ tiếp theo là nhiệm vụ trọng tâm của nghiên cứu. Đề tài hướng tới việc tối ưu hóa độ chính xác thông qua tích hợp đa nguồn dữ liệu từ cảm biến IoT và hệ thống vệ tinh khí tượng, nhằm cung cấp cơ sở khoa học cho các hệ thống cảnh báo sớm. Kết quả nghiên cứu sẽ tạo ra một công cụ hỗ trợ ra quyết định dựa trên dữ liệu, phục vụ mục tiêu xây dựng mô hình đô thị thông minh và đảm bảo an toàn môi trường sống cho cư dân TP.HCM.

1.1.2 Định hướng nghiên cứu

Nghiên cứu này định hướng triển khai các phương pháp dự báo tiên tiến nhằm giải quyết bài toán chuỗi thời gian đa biến (Multivariate Time-Series Forecasting). Trọng tâm của đề tài là xây dựng một hệ thống dự báo nồng độ bụi mịn PM2.5 có độ tin cậy và tính giải thích cao thông qua việc đối sánh và kết hợp ba nhóm phương pháp luận chủ đạo:

- **Nhóm mô hình thống kê truyền thống:** Được sử dụng để phân tích và nắm bắt các thành phần mùa vụ, xu hướng đặc thù và các mối liên hệ tuyến tính cơ bản trong dữ liệu chuỗi thời gian không khí.
- **Nhóm mô hình học máy dựa trên cấu trúc cây:** Định hướng khai thác khả năng xử lý dữ liệu dạng bảng hiệu quả và xác định mức độ quan trọng của các đặc trưng khí tượng, từ đó giúp giải thích các nhân tố then chốt ảnh hưởng đến nồng độ PM2.5.
- **Nhóm mô hình học sâu:** Ứng dụng các mạng nơ-ron hồi quy để mô hình hóa các phụ thuộc thời gian dài hạn và các mối quan hệ phi tuyến tính phức tạp trong các tập dữ liệu có độ phân giải cao.

Lộ trình nghiên cứu được xác lập dựa trên các trụ cột chính:

- **Tích hợp dữ liệu đa nguồn:** Kết hợp dữ liệu từ các cảm biến quan trắc chất lượng không khí với dữ liệu khí tượng bề mặt và khí quyển (như độ cao tầng biên, hướng gió) để tạo lập bộ đặc trưng dự báo toàn diện.
- **Đối sánh và tối ưu hóa hiệu năng:** Thực hiện quy trình đánh giá nghiêm ngặt trên các tập dữ liệu độc lập để xác định ưu thế của từng phương pháp tiếp cận. Từ đó, nghiên cứu hướng tới việc đề xuất mô hình tối ưu hoặc các cấu trúc lai (Hybrid) nhằm tận dụng tối đa thế mạnh của từng nhóm thuật toán.
- **Tự động hóa quy trình dự báo (End-to-End Pipeline):** Xây dựng hệ thống hoàn chỉnh từ khâu thu thập dữ liệu tự động cho đến khâu suy luận kết quả dự báo trong vòng 24 giờ tiếp theo, đảm bảo tính ứng dụng cao trong thực tế quản lý môi trường đô thị.

Thông qua việc kết hợp giữa nền tảng lý thuyết kiểm chứng và các kỹ thuật thực nghiệm hiện đại, nghiên cứu hướng tới việc tạo ra một khung giải pháp có khả năng dự báo chính xác diễn biến chất lượng không khí trong vòng 24 giờ tiếp theo. Kết quả nghiên cứu kỳ vọng sẽ đóng góp vào hệ thống tri thức về quản lý môi trường đô thị và hỗ trợ các giải pháp công nghệ phục vụ sức khỏe cộng đồng.

1.2 Mục tiêu nghiên cứu

1.2.1 Mục tiêu tổng quát:

Mục tiêu cốt lõi của nghiên cứu là thiết lập và chuẩn hóa một hệ thống dự báo nồng độ bụi mịn PM2.5 tại khu vực Thành phố Hồ Chí Minh với độ chính xác cao trong khung thời gian 24 giờ tiếp theo. Thông qua việc tích hợp các phương pháp luận từ khoa học dữ liệu hiện đại, nghiên cứu hướng tới việc xây dựng một cơ sở khoa học tin cậy cho các cơ chế cảnh báo sớm về ô nhiễm không khí. Kết quả của đề tài dự kiến sẽ cung cấp công cụ hỗ trợ các bên liên quan trong việc ra quyết định dựa trên dữ liệu, từ đó góp phần giảm thiểu các rủi ro sức khỏe cộng đồng và nâng cao chất lượng môi trường sống trong môi trường đô thị.

1.2.2 Mục tiêu cụ thể:

Để hiện thực hóa mục tiêu tổng quát, nghiên cứu xác lập các mục tiêu cụ thể theo lộ trình triển khai như sau:

- **Xây dựng và đồng bộ hóa cơ sở dữ liệu:** Thực hiện thu thập dữ liệu về nồng độ chất ô nhiễm và các biến số khí tượng từ nền tảng OpenAQ và Open-Meteo API tại khu vực TP.HCM. Mục tiêu là thiết lập một tập dữ liệu sạch, có độ phân giải theo giờ và đảm bảo tính liên tục từ tháng 11/2024 đến tháng 02/2026.
- **Phân tích khám phá và trích xuất tri thức (EDA):** Nhận diện các quy luật phân bố của PM2.5 theo các chu kỳ thời gian (giờ trong ngày, ngày trong tuần, tính mùa vụ) và phân tích định lượng mối tương quan giữa các yếu tố khí tượng đối với cơ chế tích tụ hoặc khuếch tán của bụi mịn.
- **Triển khai kiến trúc mô hình hóa đa phương pháp:** Thiết kế, huấn luyện và tối ưu hóa hệ thống các mô hình dự báo bao gồm: nhóm thống kê (ARIMA, ARIMAX, SARIMA, SARIMAX), nhóm học máy dựa trên cấu trúc cây (Random Forest, XGBoost, LightGBM) và nhóm mạng nơ-ron hồi quy (LSTM, GRU).
- **Đánh giá và đối sánh năng lực dự báo:** Áp dụng các chỉ số đo lường sai số tiêu chuẩn (như RMSE, MAE, MAPE) để đánh giá định lượng hiệu năng của các mô hình trên các tập dữ liệu độc lập. Từ đó, xác định cấu trúc tối ưu hoặc đề xuất các phương pháp lai nhằm nâng cao độ tin cậy của kết quả dự báo.
- **Đề xuất khung quy trình vận hành tự động:** Thiết kế kiến trúc hệ thống (Pipeline) có khả năng tự động hóa các khâu từ thu thập dữ liệu đến suy luận dự báo, tạo tiền đề kỹ thuật cho việc triển khai các ứng dụng cảnh báo chất lượng không khí trong thực tế.

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu trọng tâm của đề tài là sự biến động nồng độ của bụi mịn PM2.5 trong tầng khí quyển bề mặt tại khu vực Thành phố Hồ Chí Minh. Về mặt khoa học, bụi

mịn PM2.5 được định nghĩa là các hạt vật chất lơ lửng trong không khí có đường kính khí động học nhỏ hơn hoặc bằng 2,5 micromet (μm) [10]. Theo các tiêu chuẩn quốc tế từ Cục Bảo vệ Môi trường Hoa Kỳ (EPA) và Tổ chức Y tế Thế giới (WHO), do kích thước siêu nhỏ, các hạt này sở hữu khả năng thâm nhập sâu vào cấu trúc phế nang và hệ thống mạch máu, đồng thời có thời gian lưu tại khí quyển lâu hơn so với các hạt bụi có kích thước lớn. Nghiên cứu thực hiện phân tích các quy luật phụ thuộc và mối quan hệ tương tác (bao gồm cả tuyến tính và phi tuyến tính) giữa nồng độ PM2.5 với chuỗi các thông số khí tượng động học như nhiệt độ, độ ẩm tương đối, áp suất bề mặt, tốc độ gió, hướng gió và độ cao tầng biên khí quyển [11].

1.3.2 Phạm vi nghiên cứu

Đề tài được xác lập giới hạn thực hiện trong các phạm vi cụ thể sau:

- **Phạm vi không gian:** Khu vực Thành phố Hồ Chí Minh. Dữ liệu quan trắc được thu thập từ các trạm đại diện cho chất lượng không khí đô thị, phản ánh đặc trưng của một siêu đô thị đang phát triển.

- **Phạm vi thời gian:** Tập dữ liệu phục vụ huấn luyện và đánh giá mô hình được giới hạn trong khoảng thời gian từ tháng 11/2024 đến tháng 02/2026. Đây là giai đoạn cung cấp đủ độ dài dữ liệu (data length) để thực hiện các phân tích về tính chu kỳ và mô hình hóa các xu hướng biến động của bụi mịn.

- **Phạm vi nội dung:** Nghiên cứu tập trung giải quyết bài toán dự báo nồng độ bụi mịn PM2.5 trong ngắn hạn (khung thời gian 24 giờ tiếp theo). Nội dung bao hàm việc thiết kế và đối sánh hiệu năng giữa các nhóm thuật toán Thống kê, Học máy dựa trên cấu trúc cây và Học sâu nhằm xác lập phương pháp tối ưu cho cấu trúc dữ liệu chuỗi thời gian đa biến.

Chapter 2

CƠ SỞ LÝ THUYẾT

2.1 Các yếu tố khí tượng ảnh hưởng đến PM2.5

Sự biến động nồng độ bụi mịn PM2.5 trong khí quyển không chỉ phụ thuộc vào cường độ phát thải từ các nguồn nhân tạo mà còn chịu sự chi phối mạnh mẽ bởi các điều kiện khí tượng. Các điều kiện này quyết định khả năng tích tụ, khuếch tán, vận chuyển và loại bỏ các hạt vật chất trong không gian đô thị [6]. Để xây dựng mô hình dự báo chính xác, nghiên cứu thực hiện khai thác dữ liệu từ hai nền tảng dữ liệu mở uy tín, cung cấp các thông số đặc trưng cho chất lượng không khí và động lực học khí quyển.

2.1.1 Dữ liệu Chất lượng không khí (OpenAQ)

OpenAQ là nền tảng dữ liệu mở toàn cầu, chuyên tổng hợp và chuẩn hóa dữ liệu chất lượng không khí thời gian thực từ các hệ thống cảm biến IoT (Internet of Things). Nghiên cứu thực hiện trích xuất chuỗi nồng độ bụi mịn PM2.5 (μg/m^3) làm đại diện cho chỉ số mục tiêu. Việc dự báo nồng độ PM2.5 trong khung thời gian 24 giờ tiếp theo được xác định là nhiệm vụ trọng tâm, đóng vai trò nền tảng cho việc thiết lập các cơ chế cảnh báo sớm nhằm giảm thiểu rủi ro sức khỏe cộng đồng.

2.1.2 Dữ liệu Khí tượng (Open-Meteo API)

Open-Meteo API cung cấp dữ liệu khí tượng dựa trên các mô hình tái phân tích hiện đại, tiêu biểu là mô hình ERA5 của Trung tâm Dự báo Thời tiết Tầm trung Châu Âu (ECMWF). Nghiên cứu tích hợp 08 đặc trưng khí tượng được xác định là có ảnh hưởng quyết định đến khả năng tích tụ và khuếch tán của PM2.5 [11]:

- **Cơ chế nhiệt và ẩm:** Bao gồm nhiệt độ (2m), độ ẩm tương đối và lượng mưa. Các yếu tố này tác động đến sự biến đổi lý tính của hạt bụi và hỗ trợ cơ chế rửa trôi khí quyển tự nhiên.
- **Cơ chế động lực học:** Tốc độ gió, hướng gió và áp suất bề mặt. Đây là các tác nhân trực tiếp tham gia vào quá trình pha loãng và vận chuyển chất ô nhiễm theo phương ngang.
- **Cơ chế ổn định khí quyển:** Nhiệt độ ở độ cao 180m và độ cao tầng biên khí quyển (Boundary Layer Height). Các chỉ số này cho phép nhận diện trạng thái ổn định

của lớp không khí sát đất, nơi PM2.5 có xu hướng tích tụ nồng độ cao khi không gian khuếch tán theo phương thẳng đứng bị giới hạn.

2.2 Ứng dụng học máy trong dự báo chất lượng không khí

Trong những năm gần đây, phương pháp tiếp cận bài toán dự báo chất lượng không khí đã có sự chuyển dịch mạnh mẽ từ các mô hình mô phỏng hóa lý truyền thống sang các hướng tiếp cận dựa trên dữ liệu (Data-driven). Sự kết hợp giữa các phương pháp thống kê học cổ điển và các thuật toán học máy hiện đại cho phép khai thác hiệu quả các quy luật phức tạp ẩn trong chuỗi dữ liệu nồng độ PM2.5.

2.2.1 Nhóm mô hình thống kê (ARIMA, ARIMAX, SARIMA, SARIMAX)

Các mô hình thống kê tự hồi quy đóng vai trò là nền tảng trong phân tích chuỗi thời gian nhờ tính minh bạch và khả năng diễn giải toán học cao. Nghiên cứu thực hiện đối sánh trên 04 biến thể chính:

- **ARIMA (Autoregressive Integrated Moving Average):** Mô hình cơ bản kết hợp giữa thành phần tự hồi quy (AR), sai phân tích hợp (I) để đưa chuỗi về tính dừng, và trung bình trượt (MA) để xử lý sai số dự báo.
- **ARIMAX:** Mở rộng từ ARIMA bằng cách tích hợp trực tiếp các biến ngoại sinh (Exogenous variables). Điều này cho phép mô hình xem xét các tác động từ bên ngoài như yếu tố khí tượng đồng thời với quy luật của chính chuỗi PM2.5.
- **SARIMA (Seasonal ARIMA):** Biến thể bổ sung các tham số mùa vụ để nắm bắt các quy luật lặp lại theo chu kỳ (ví dụ: chu kỳ ngày-đêm hoặc mùa vụ trong năm) thường thấy trong dữ liệu chất lượng không khí.
- **SARIMAX:** Là cấu trúc phức tạp nhất trong nhóm này, kết hợp đầy đủ các thành phần tự hồi quy, tích hợp, trung bình trượt cùng với các đặc tính mùa vụ và tác động của các biến ngoại sinh. Đây là mô hình thống kê chủ đạo được sử dụng để đối sánh hiệu năng trong nghiên cứu.

2.2.2 Nhóm mô hình dựa trên cấu trúc cây (Random Forest, Gradient Boosting)

Các thuật toán dựa trên cây quyết định (Decision Trees) đặc biệt hiệu quả trong việc xử lý các quan hệ phi tuyến tính và các tập dữ liệu có nhiều biến số tương tác phức tạp.

- **Random Forest:** Sử dụng kỹ thuật Bagging và chọn lọc đặc trưng ngẫu nhiên để xây dựng tập hợp nhiều cây quyết định độc lập. Phương pháp này giúp giảm thiểu hiện tượng quá khớp (overfitting) và tăng cường độ bền vững cho dự báo.
- **XGBoost và LightGBM:** Dựa trên cơ chế Gradient Boosting, các thuật toán này xây dựng các cây quyết định tuần tự nhằm tối ưu hóa hàm mục tiêu. Chúng nổi bật với tốc độ huấn luyện cao, khả năng xử lý dữ liệu quy mô lớn và cung cấp khả năng đánh giá mức độ đóng góp của từng đặc trưng (Feature Importance), giúp nhận diện các nhân tố khí tượng ảnh hưởng nhất đến PM2.5.

2.2.3 Nhóm mạng nơ-ron hồi quy (LSTM, GRU)

Đối với dữ liệu chuỗi thời gian có các đặc trưng phụ thuộc dài hạn, các kiến trúc mạng nơ-ron tái phát (RNN) là lựa chọn tối ưu nhờ khả năng ghi nhớ thông tin qua các bước thời gian.

- **LSTM (Long Short-Term Memory):** Sử dụng cơ chế các cổng (Input, Forget, Output gates) để điều soát dòng thông tin đi qua các trạng thái ẩn. Cấu trúc này giải quyết hiệu quả vấn đề triệt tiêu đạo hàm (vanishing gradient), cho phép mô hình học được các quy luật biến động kéo dài trong chuỗi dữ liệu không khí.
- **GRU (Gated Recurrent Unit):** Là biến thể tinh giản của LSTM, kết hợp các cổng thành cấu trúc Update gate và Reset gate. GRU giúp tối ưu hóa hiệu năng tính toán và thời gian huấn luyện trong khi vẫn duy trì được năng lực dự báo tương đương với LSTM.

Chapter 3

DỮ LIỆU VÀ QUY TRÌNH PHÂN TÍCH

3.1 Dữ liệu thô (Raw Data)

Dữ liệu thô của nghiên cứu được tổng hợp và đồng bộ hóa từ hai nguồn API chính, tạo thành một tập dữ liệu chuỗi thời gian hợp nhất với độ phân giải theo giờ (hourly resolution). Tập dữ liệu bao phủ giai đoạn từ tháng 11/2024 đến tháng 02/2026 tại khu vực Thành phố Hồ Chí Minh.

3.1.1 Dữ liệu nồng độ bụi từ OpenAQ

Dữ liệu nồng độ chất ô nhiễm được thu thập thông qua giao diện lập trình ứng dụng (API) của nền tảng OpenAQ (phiên bản V3). Nghiên cứu thực hiện truy vấn dữ liệu từ trạm quan trắc đặt tại Lãnh sự quán Hoa Kỳ tại TP.HCM (Location ID: 3276359), trạm quan trắc này được lựa chọn nhờ tính ổn định và độ tin cậy cao của dữ liệu trong khu vực đô thị. Các đặc trưng thô được trích xuất trực tiếp từ quy trình thu thập bao gồm:

- **Nhóm nồng độ bụi mịn:** ‘pm25‘, ‘pm10‘, ‘pm1‘ (μg/m^3) và chỉ số đếm hạt bụi siêu mịn ‘um003‘. Trong đó, ‘pm25‘ đóng vai trò là biến số cốt lõi để xây dựng biến mục tiêu cho mô hình dự báo.
- **Nhóm bổ trợ tại trạm:** Các cảm biến tại trạm cung cấp thêm thông số về ‘temperature‘ (nhiệt độ) và ‘relativehumidity‘ (độ ẩm tương đối) tại vị trí quan trắc.
- **Trục thời gian:** `datetime_local` (múi giờ địa phương), đảm bảo tính đồng bộ tuyệt đối khi kết hợp với các nguồn dữ liệu khí tượng vệ tinh.

Quy trình thu thập được tự động hóa bằng ngôn ngữ Python thông qua các mô-đun được xây dựng riêng cho dự án, thực hiện truy vấn và lưu trữ theo từng tháng để tối ưu hóa quản lý dữ liệu. Kết quả thu được là một tập dữ liệu thô gồm 9.418 bản ghi, tạo tiền đề quan trọng cho các công đoạn làm sạch dữ liệu cơ bản.

3.1.2 Dữ liệu khí tượng từ Open-Meteo API

Quy trình thu thập dữ liệu khí tượng (đóng vai trò là các biến ngoại sinh – Exogenous Variables) được thực hiện thông qua giao diện lập trình ứng dụng Open-Meteo Archive

API dựa trên mô hình tái phân tích ERA5. Đây là nguồn dữ liệu quan trọng giúp mô hình học được các tương quan vật lý giữa biến động khí quyển và nồng độ chất ô nhiễm. Dựa trên cấu trúc triển khai thực tế của các thuật toán được xây dựng cho dự án, các thông số kỹ thuật được xác lập như sau:

- **Nguồn dữ liệu:** Sử dụng Endpoint `archive-api.open-meteo.com/v1/archive` để trích xuất dữ liệu lịch sử ổn định.
- **Tham số vị trí:** Truy vấn được thực hiện tại tọa độ định danh 10.8231°N (Vĩ độ) và 106.6297°E (Kinh độ), tương ứng với vị trí trạm quan trắc tại khu vực trung tâm TP.HCM.
- **Khung thời gian:** Dữ liệu bao phủ liên tục từ ngày 01/11/2024 đến 10/02/2026 với múi giờ được chuẩn hóa là `Asia/Ho_Chi_Minh`.
- **Phương thức thực hiện:** Sử dụng thư viện `requests` để gửi tham vấn API và `pandas` để chuyển đổi cấu trúc JSON sang định dạng bảng. Toàn bộ 08 biến số khí tượng được tải về đồng thời trong một truy vấn duy nhất để đảm bảo tính đồng bộ tuyệt đối về mặt thời gian.

Danh sách các biến số khí tượng được thu thập tích hợp bao gồm:

- **temperature_2m (°C) & relative_humidity_2m (%):** Nhiệt độ và độ ẩm tại độ cao 02 mét.
- **precipitation (mm):** Lượng mưa tích lũy theo giờ.
- **surface_pressure (hPa):** Áp suất khí quyển tại bề mặt.
- **wind_speed_10m (m/s) & wind_direction_10m (°):** Tốc độ và hướng gió tại độ cao 10 mét.
- **temperature_180m (°C):** Nhiệt độ khí quyển tại độ cao 180 mét.
- **boundary_layer_height (m):** Độ cao của tầng biên khí quyển tại thời điểm quan trắc.

Tập dữ liệu khí tượng sau khi tải về là dữ liệu nền tảng cho giai đoạn tiền xử lý và hợp nhất chuỗi thời gian.

3.2 Làm sạch dữ liệu cơ bản (Basic Cleaning)

Sau khi thu thập từ các nguồn API khác nhau, dữ liệu thô được đưa vào quy trình làm sạch sơ bộ nhằm đảm bảo tính toàn vẹn và đồng bộ cho các bước phân tích tiếp theo. Các thao tác chính trong giai đoạn này bao gồm:

- **Chuẩn hóa trục thời gian:** Dữ liệu thời gian của cả hai nguồn được chuyển đổi sang định dạng `datetime` tiêu chuẩn. Nhằm đảm bảo phép hợp nhất diễn ra chính xác, các thông tin về múi giờ được xử lý đưa về dạng nguyên bản (*timezone-naive*).
- **Hợp nhất dữ liệu đa nguồn:** Nghiên cứu thực hiện phép hợp nhất trái (*Left Join*) với dữ liệu nồng độ bụi mịn làm trục chính. Việc đồng bộ hóa được thực thi dựa trên sự khớp nối chính xác giữa các mốc thời gian theo giờ từ nguồn OpenAQ và các biến số ngoại sinh từ Open-Meteo.

- **Tối ưu hóa cấu trúc chuỗi thời gian:** Tập dữ liệu sau khi hợp nhất được sắp xếp theo trình tự thời gian tăng dần. Trục thời gian sau đó được thiết lập làm chỉ mục (*Index*) của tập dữ liệu, tạo điều kiện thuận lợi cho việc khai thác các đặc trưng trễ (*lag features*) và các thành phần mùa vụ ở các giai đoạn sau.

- **Dọn dẹp hậu hợp nhất:** Loại bỏ các trường dữ liệu trùng lặp hoặc các cột trung gian phát sinh trong quá trình kết nối bảng. Đồng thời, nghiên cứu thực hiện kiểm tra và loại bỏ các đặc trưng có tỷ lệ dữ liệu bị thiếu (*missing values*) quá cao để tránh gây nhiễu cho mô hình. Cụ thể, biến `pm10` (thiếu 86%) và `temperature_180m` (thiếu 100%) đã bị loại bỏ hoàn toàn khỏi tập dữ liệu nghiên cứu do không đảm bảo tính đại diện thống kê.

Kết quả của giai đoạn làm sạch cơ bản là một tập dữ liệu hợp nhất gồm 9.418 bản ghi, bao hàm đầy đủ thông tin về nồng độ bụi mịn và 08 đặc trưng khí tượng tương ứng cho mỗi khung giờ tại khu vực nghiên cứu.

3.3 Phân tích khám phá (EDA - Train Only)

Quá trình phân tích dữ liệu khám phá được thực hiện trên tập huấn luyện (tương ứng với 60% tổng dữ liệu theo trình tự thời gian) nhằm ngăn chặn hiện tượng rò rỉ thông tin từ tương lai vào mô hình. Quy trình này được cấu trúc theo ba cấp độ tiếp cận: đơn biến, nhị biến và đa biến.

3.3.1 Phân tích đơn biến (Univariate Analysis)

Phân tích đơn biến đóng vai trò nhận diện các đặc tính phân phối thống kê và xác định mức độ hiện diện của các giá trị ngoại lai trong từng biến số độc lập.

Đặc tính phân phối của các hạt bụi mịn

Phân phối của các chỉ số PM2.5, PM1 và UM003 đều thể hiện dạng lệch phải (*Right-skewed*) đặc trưng của dữ liệu nồng độ chất ô nhiễm trong không khí đô thị.

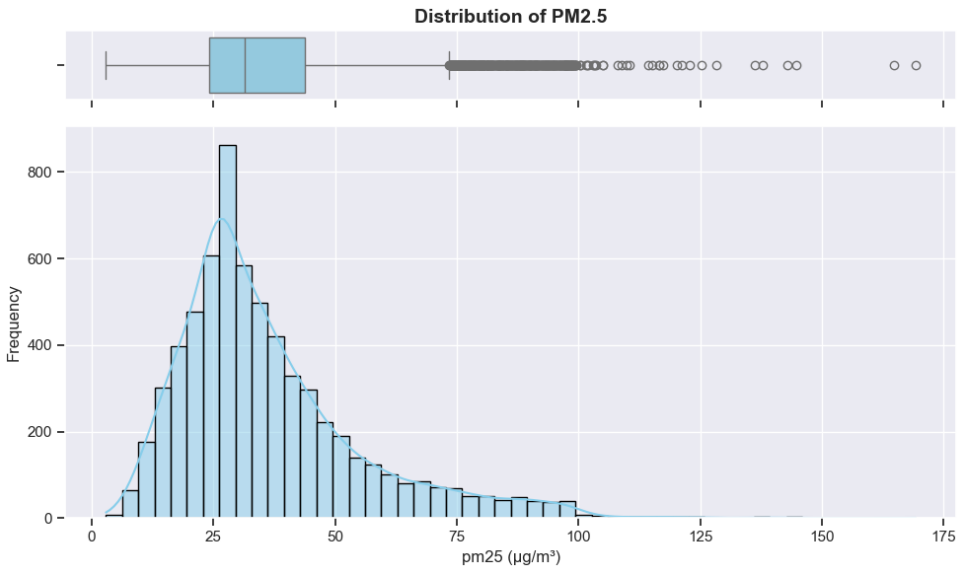

Figure 3.1: Phân phối nồng độ PM2.5 trong tập huấn luyện (Histplot và Boxplot)

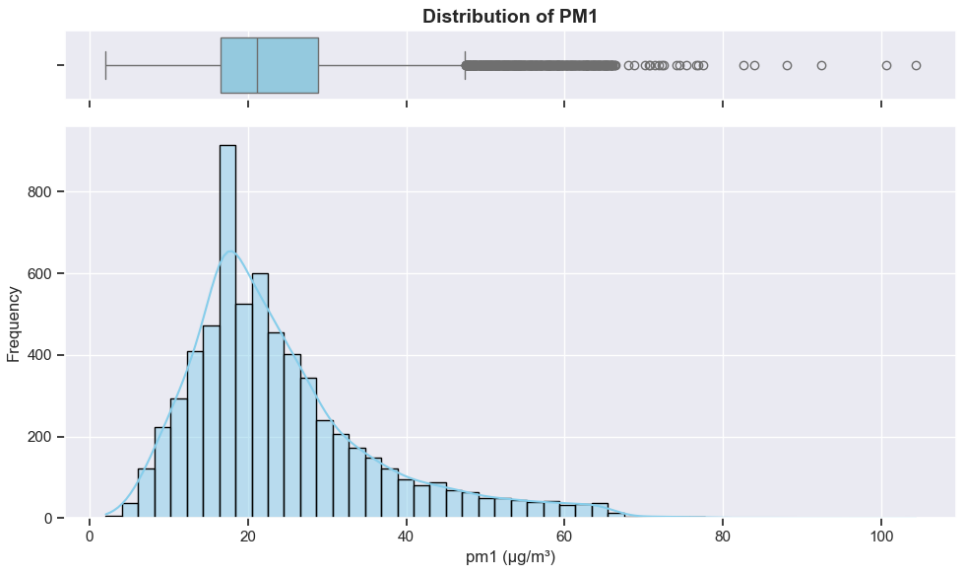

Figure 3.2: Phân phối nồng độ PM1 trong tập huấn luyện (Histplot và Boxplot)

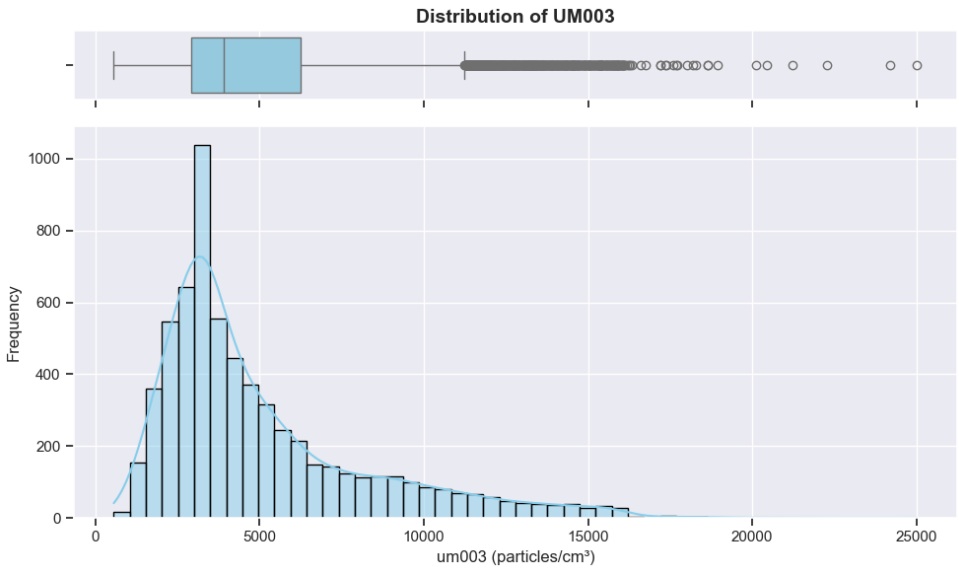

Figure 3.3: Phân phối mật độ hạt bụi mịn kích thước $> 0.3\mu m$ (UM003)

- **PM2.5:** Giá trị đỉnh tập trung quanh ngưỡng 25–35 $\mu g/m^3$. Đáng chú ý, tập dữ liệu xuất hiện nhiều giá trị ngoại lai vượt mức 100 $\mu g/m^3$. Theo kết quả đối chiếu, các đỉnh ô nhiễm này thường tương ứng với các sự kiện khí tượng đặc biệt như nghịch nhiệt (*Temperature Inversion*), khiến bụi mịn bị giữ lại ở tầng thấp không thể khuếch tán [7].

- **PM1 và UM003:** Phân phối của hai biến này gần như đồng dạng với PM2.5. Sự tương quan chặt chẽ này khẳng định PM2.5 là thành phần chủ đạo bao hàm cả các hạt siêu mịn (PM1), đồng thời cho thấy việc sử dụng đồng thời cả ba chỉ số có thể dẫn đến hiện tượng đa cộng tuyến (*Multicollinearity*) trong quá trình huấn luyện mô hình.

Đối sánh dữ liệu khí tượng giữa hai nguồn trạm và vệ tinh

Nghiên cứu thực hiện so sánh phân phối giữa cảm biến tại trạm (OpenAQ) và mô hình tái phân tích khí quyển (Open-Meteo) để đánh giá độ tin cậy.

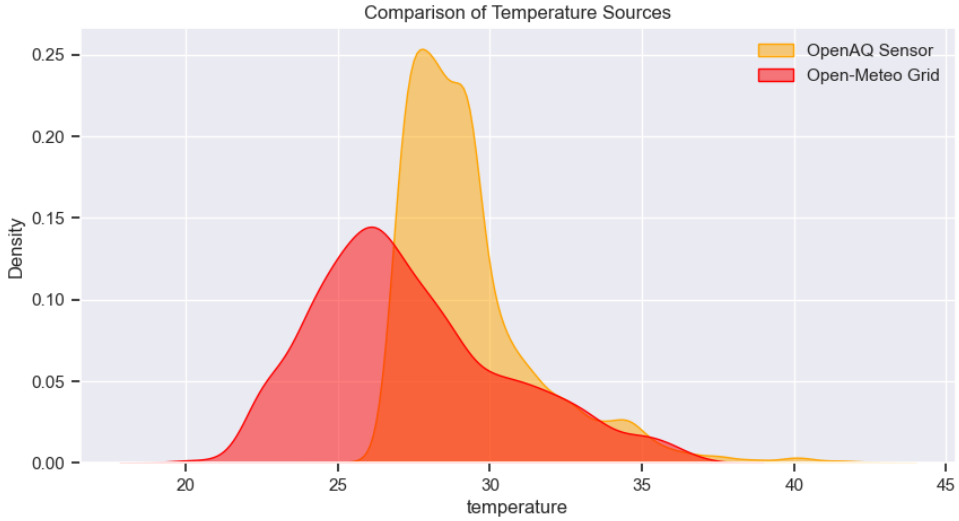

Figure 3.4: Đối sánh phân phối Nhiệt độ giữa nguồn OpenAQ và Open-Meteo

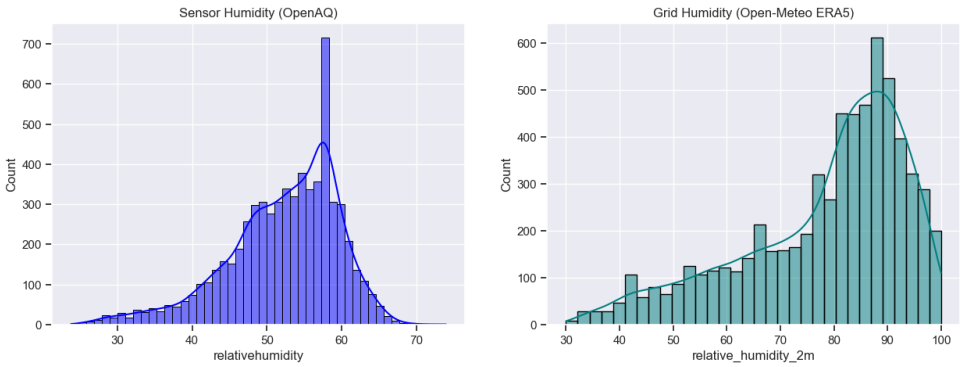

Figure 3.5: Đối sánh phân phối Độ ẩm giữa nguồn OpenAQ và Open-Meteo

- **Nhiệt độ (Temperature):** Cả hai nguồn đều thể hiện phân phối hai đỉnh (*Bimodal*), phản ánh chu kỳ nhiệt ngày và đêm rõ rệt của khí hậu nhiệt đới. Tuy nhiên, nhiệt độ ghi nhận tại trạm (OpenAQ) thường cao hơn khoảng 1–2°C so với dữ liệu vệ tinh, điều này có thể giải thích bởi hiệu ứng đảo nhiệt đô thị (*Urban Heat Island*) tại vị trí đặt trạm thực tế.
- **Độ ẩm (Humidity):** Phân phối độ ẩm từ Open-Meteo có xu hướng mượt hơn (*Smoothed*) so với dữ liệu trạm. Điều này cho thấy dữ liệu mô hình ERA5 đã trung bình hóa các biến động cực bộ, trong khi cảm biến tại chỗ phản ánh chính xác các biến động độ ẩm tức thời do các yếu tố môi trường xung quanh.

Các đặc trưng khí quyển và động lực học

Ngoài nhiệt độ và độ ẩm, các biến số khí quyển khác từ nguồn Open-Meteo cung cấp cái nhìn sâu sắc về các cơ chế khuếch tán và lắng đọng của bụi mịn.

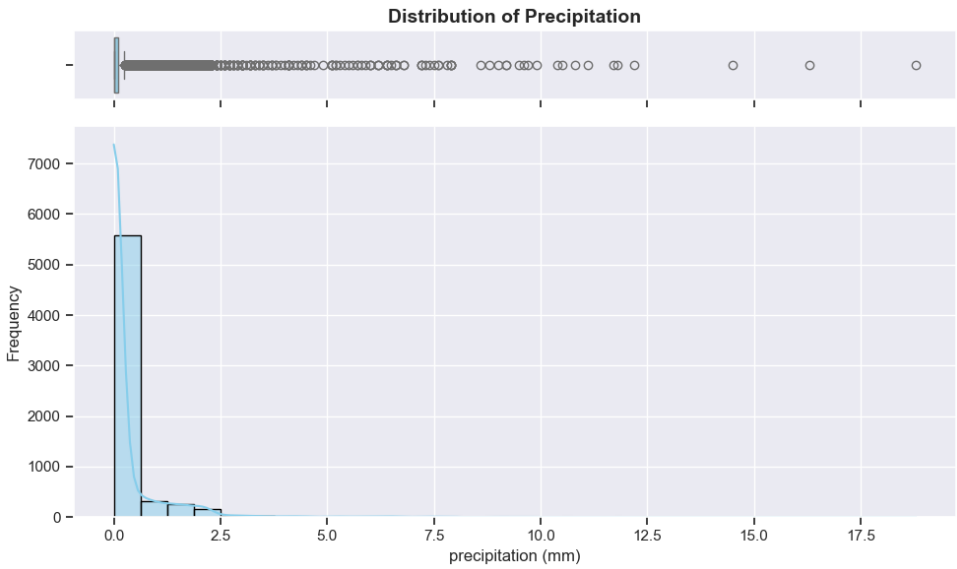

Figure 3.6: Phân phối lượng mưa tích lũy theo giờ (Precipitation)

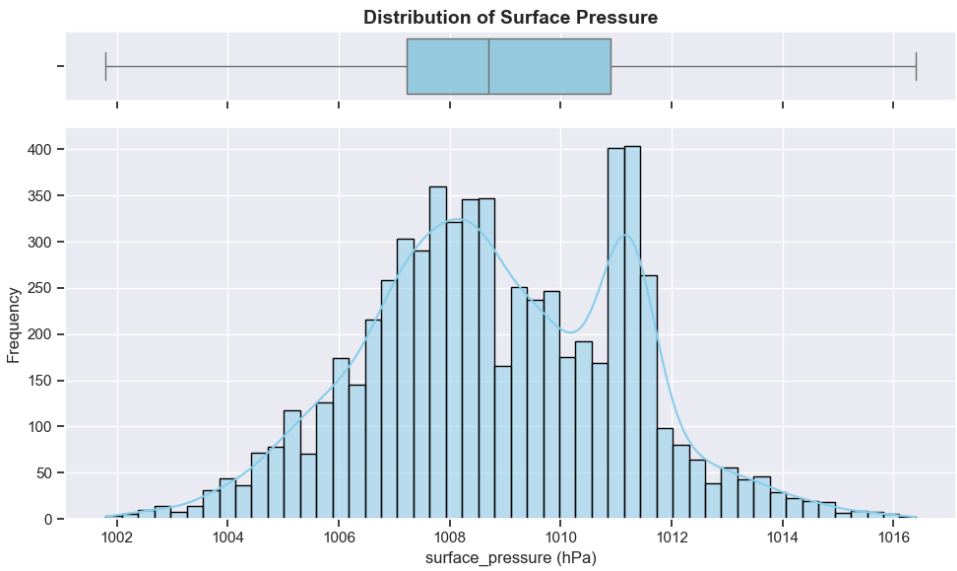

Figure 3.7: Phân phối áp suất bề mặt (Surface Pressure)

- **Lượng mưa (Precipitation):** Tập dữ liệu cho thấy đặc tính phân phối rời rạc với tần suất các giờ không mưa chiếm ưu thế tuyệt đối. Lượng mưa là nhân tố then chốt thực hiện quá trình lắng đọng ướt (*Wet deposition*), giúp loại bỏ các hạt PM2.5 ra khỏi khí quyển thông qua cơ chế rửa trôi [10].
- **Áp suất bề mặt (Surface Pressure):** Biến số này biến động trong khoảng hẹp 1005–1015 hPa. Áp suất cao thường tương ứng với các trạng thái khí quyển ổn định, làm hạn chế sự khuếch tán thẳng đứng của các khối khí ô nhiễm [11].

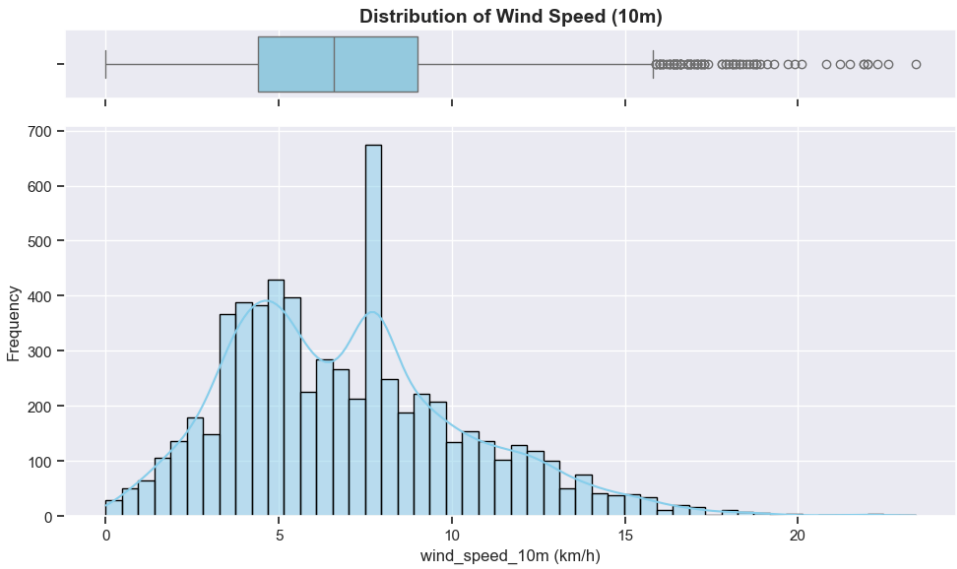

Figure 3.8: Phân phối tốc độ gió tại độ cao 10m (Wind Speed)

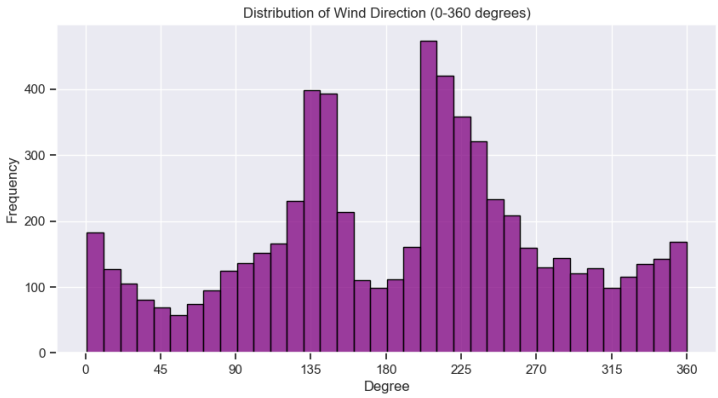

Figure 3.9: Biểu đồ hoa gió thể hiện hướng và tốc độ gió thịnh hành (Wind Rose)

- **Tốc độ và hướng gió:** Tốc độ gió tập trung chủ yếu ở dải 2–6 m/s. Tốc độ gió thấp thường dẫn đến hiện tượng đình trệ khí quyển (*Stagnation*), là nguyên nhân chính gây ra các đợt tích tụ bụi mịn cục bộ. Biểu đồ hoa gió giúp xác định các hướng vận chuyển chất ô nhiễm chủ đạo từ các khu vực phát thải lân cận.

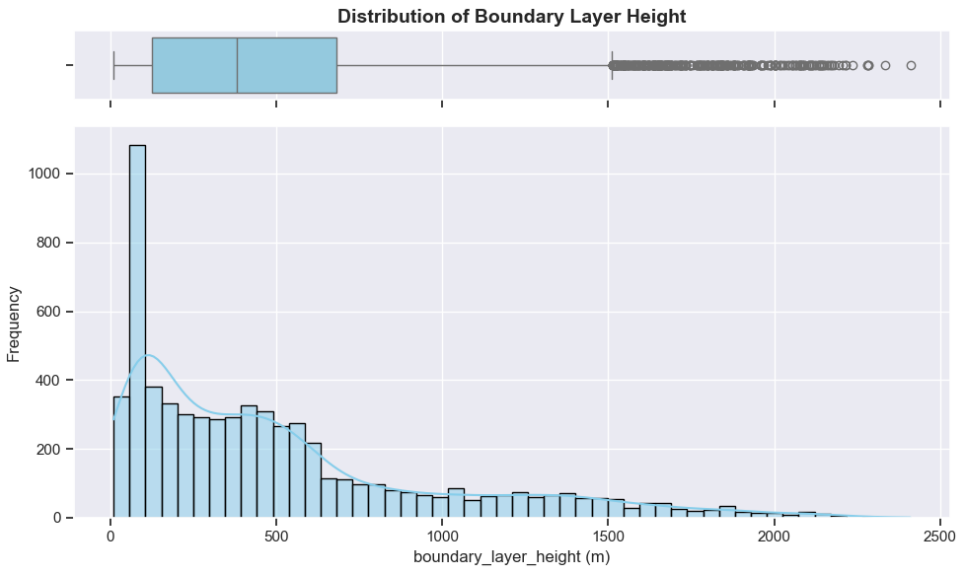

Figure 3.10: Phân phối độ cao tầng biên khí quyển (Boundary Layer Height)

- **Độ cao tầng biên (BLH):** BLH thể hiện sự biến thiên lớn giữa ngày và đêm. Một tầng biên nông (thấp) sẽ nén không gian thể tích khả dụng cho việc pha trộn bụi mịn, dẫn đến nồng độ quan trắc được tăng cao ngay cả khi cường độ nguồn thải không thay đổi [11].

3.3.2 Phân tích nhị biến (Bivariate Analysis)

Phân tích nhị biến tập trung vào việc làm rõ mối tương quan giữa nồng độ PM2.5 với các nhóm đặc trưng khí tượng và các yếu tố thời gian, từ đó định hình chiến lược lựa chọn đặc trưng (*Feature Selection*) hiệu quả.

Phân tích ma trận tương quan (Correlation Analysis)

Hệ số tương quan Pearson được sử dụng để đánh giá mức độ liên kết tuyến tính giữa các cặp biến số trong tập dữ liệu.

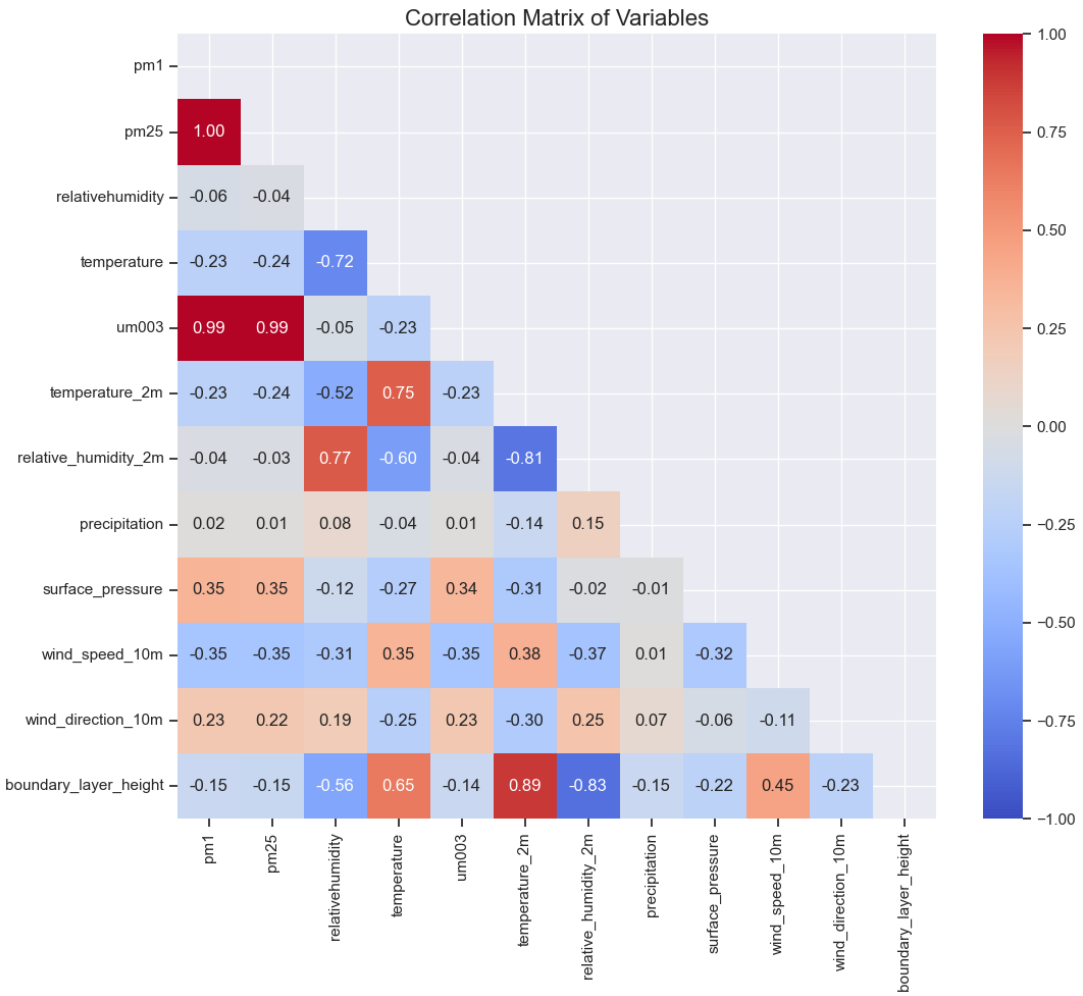

Figure 3.11: Ma trận tương quan Pearson giữa nồng độ bụi mịn và các biến khí tượng

- **Đa cộng tuyến giữa các kích cỡ hạt bụi:** PM2.5 thể hiện sự tương quan cực kỳ chặt chẽ ($r \approx 0.99$) với PM1 và UM003. Kết quả này gợi ý rằng các hạt bụi kích thước khác nhau có cùng nguồn gốc phát thải và cơ chế vận chuyển. Để tối ưu hóa mô hình và tránh hiện tượng đa cộng tuyến (*Multicollinearity*), các biến PM1 và UM003 sẽ được loại bỏ trong giai đoạn tiền xử lý.

- **Tương quan với các biến ngoại sinh:** PM2.5 có tương quan nghịch rõ rệt với độ cao tầng biên (BLH) và tốc độ gió. Điều này phù hợp với lý thuyết về sự pha loãng chất ô nhiễm: khi gió mạnh và tầng biên cao, thể tích không khí để bụi mịn khuếch tán tăng lên, dẫn đến nồng độ quan trắc được giảm xuống [10].

Các quy luật biến động theo thời gian (Temporal patterns)

Nồng độ bụi mịn tại khu vực nghiên cứu thể hiện các đặc tính mang tính chu kỳ rõ rệt, phản ánh sự tương tác giữa hoạt động của con người và các hiện tượng tự nhiên.

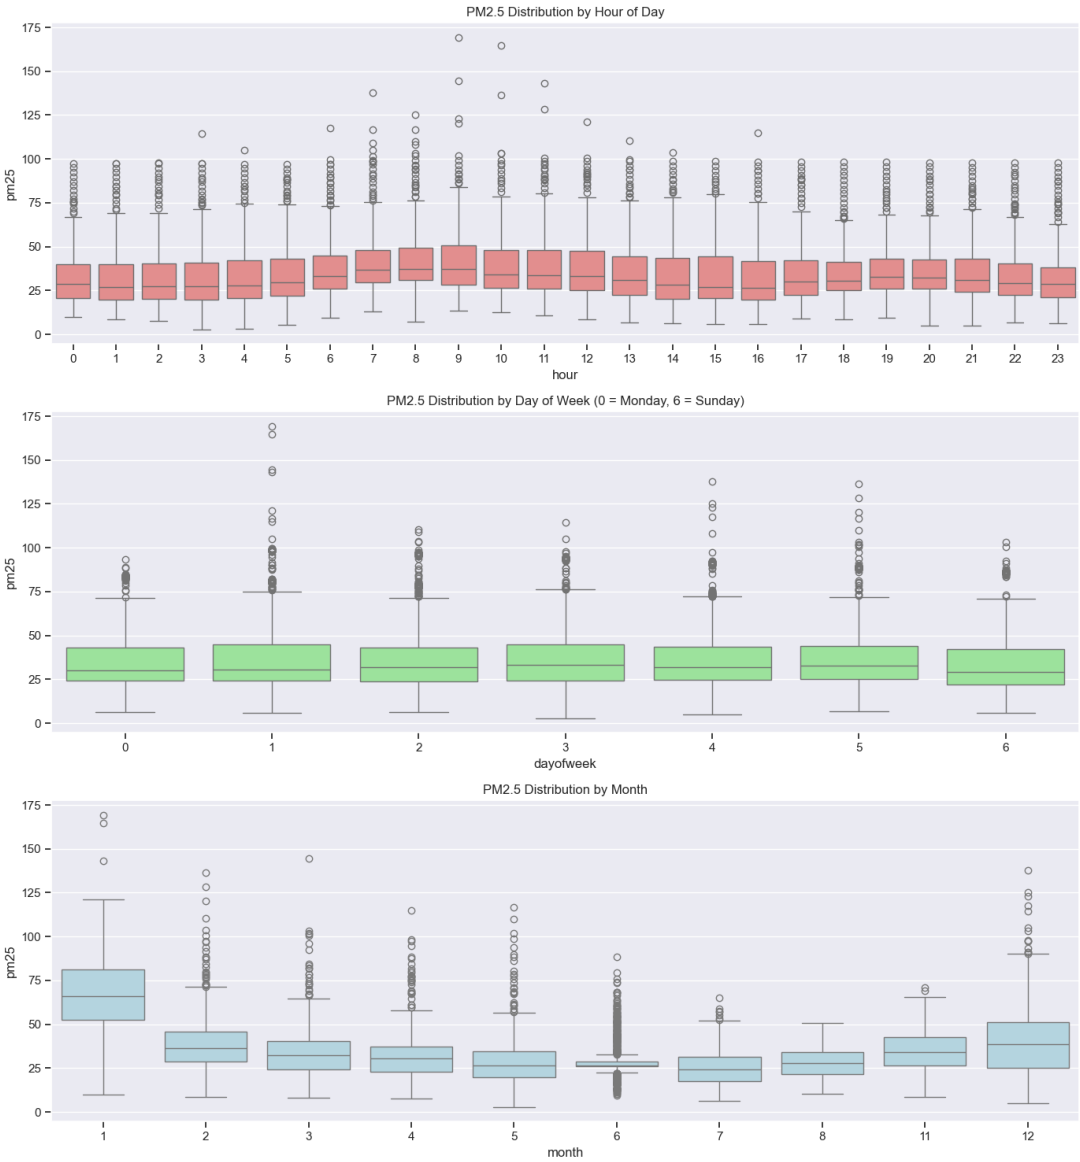

Figure 3.12: Quy luật biến động thời gian của nồng độ PM2.5 trong ngày, trong tuần và trong tháng

- **Chu kỳ giờ trong ngày (Diurnal Cycle):** Biểu đồ nồng độ theo giờ thể hiện đặc tính hai đỉnh (*Bimodal*). Đỉnh thứ nhất xuất hiện vào khoảng 7h–9h sáng, trùng với giờ cao điểm giao thông. Đỉnh thứ hai cao và kéo dài hơn xuất hiện vào đêm khuya (sau 20h), thời điểm tầng biên khí quyển hạ xuống thấp nhất, gây ra hiện tượng tích tụ chất ô nhiễm gần bề mặt [11].

- **Chu kỳ ngày trong tuần (Weekly Cycle):** Nồng độ trung bình có xu hướng giảm vào các ngày cuối tuần, phản ánh sự sụt giảm trong lưu lượng giao thông công nghiệp và hoạt động xây dựng trong thành phố.

- **Biến động theo tháng (Monthly Variation):** Nồng độ bụi mịn thể hiện sự khác biệt rõ rệt giữa mùa khô và mùa mưa. Các tháng cuối năm và đầu năm (tháng 11, 12, 1) ghi nhận nồng độ cao vượt trội do điều kiện khí quyển ổn định và ít mưa. Ngược lại, các tháng giữa năm (tháng 6, 7, 8) có nồng độ thấp và ổn định hơn nhờ hiệu ứng rửa trôi của mưa [10].

Lưu ý: Do quy trình EDA chỉ thực hiện trên tập huấn luyện (Train Only) bao gồm 60% dữ liệu đầu tiên theo trục thời gian (từ tháng 11/2024 đến tháng 08/2025), nên các tháng 9 và tháng 10 không xuất hiện trong phân tích này. Việc giới hạn không gian phân tích trong tập Huấn luyện là cần thiết để đảm bảo tính khách quan cho quá trình tối ưu hóa mô hình sau này.

Tương quan giữa nồng độ PM2.5 và các yếu tố khí tượng

Việc phân tích các mối quan hệ nhị biến trực tiếp giữa bụi mịn và các điều kiện vật lý giúp hiểu rõ cơ chế khuếch tán và tích tụ tại địa phương.

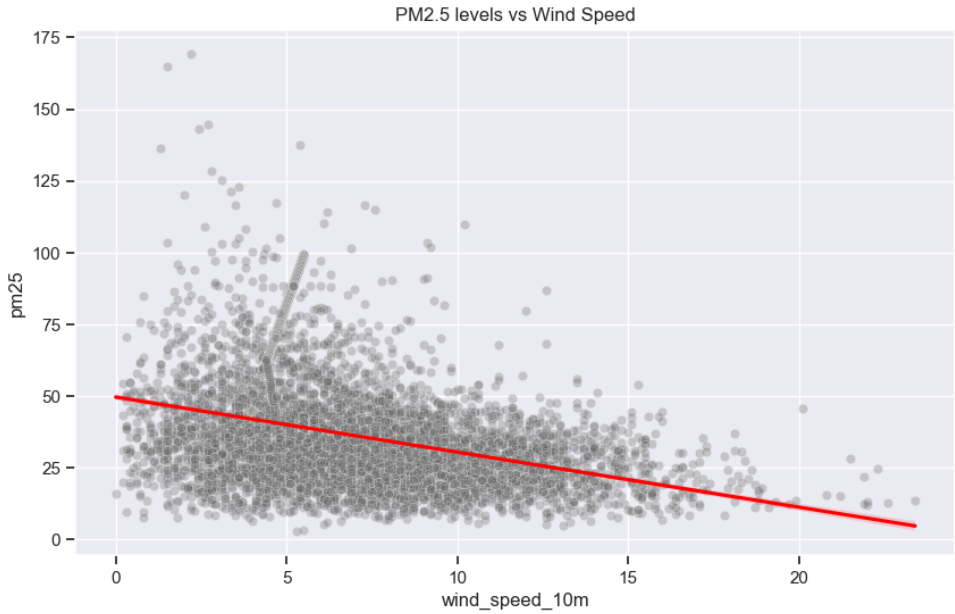

Figure 3.13: Mối quan hệ nghịch biến giữa nồng độ PM2.5 và tốc độ gió

- **PM2.5 và Tốc độ gió:** Kết quả thể hiện mối quan hệ nghịch biến rõ rệt. Khi tốc độ gió vượt ngưỡng 4 m/s, nồng độ PM2.5 giảm xuống mức thấp và ổn định. Điều này được giải thích bởi sự gia tăng năng lượng pha loãng và vận chuyển ngang của các khối khí ô nhiễm. Ngược lại, các điều kiện "lặng gió" (< 1.5 m/s) là tiền đề cho các sự kiện tích tụ ô nhiễm nghiêm trọng do chất thải từ giao thông không thể phát tán [11].

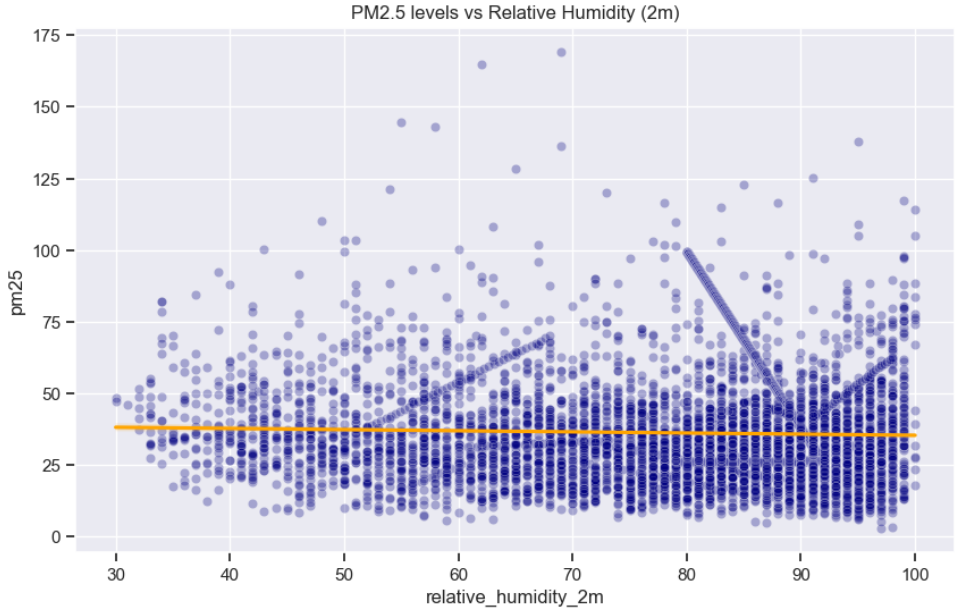

Figure 3.14: Phân tích biến thiên nồng độ PM2.5 theo độ ẩm tương đối

- **PM2.5 và Độ ẩm:** Mối quan hệ này có tính phức tạp và phụ thuộc vào ngưỡng. Trong dải độ ẩm từ 50% đến 80%, nồng độ PM2.5 có xu hướng tăng tỷ lệ thuận với độ ẩm do cơ chế tăng trưởng hút ẩm (*Hygroscopic growth*), khiến các sol khí liên kết với hơi nước và tăng trọng lượng [10]. Tuy nhiên, ở các ngưỡng độ ẩm cực cao ($> 90\%$), nồng độ thường giảm mạnh, phản ánh sự xuất hiện của mưa và quá trình rửa trôi khí quyển.

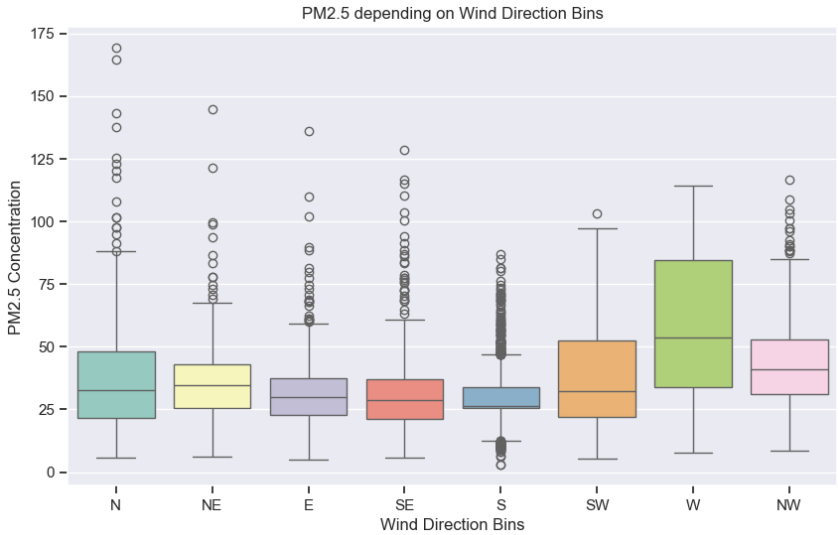

Figure 3.15: Phân bổ nồng độ PM2.5 trung bình theo các hướng gió chính

- **PM2.5 và Hướng gió:** Sự phân bổ nồng độ bụi theo hướng gió cho thấy tính bất đẳng hướng rõ rệt. Các hướng gió mang nồng độ cao thường tương ứng với các luồng khí thổi từ phía các khu công nghiệp phụ cận hoặc dọc theo các trục lộ giao thông huyết mạch của TP.HCM, chứng minh tầm quan trọng của nguồn phát thải liên tỉnh và liên vùng đối với chất lượng không khí đô thị.

3.3.3 Phân tích đa biến (Multivariate Analysis)

Giai đoạn cuối của quá trình EDA tập trung vào việc bóc tách các thành phần cấu trúc của chuỗi thời gian và nhận diện nguồn phát thải thông qua sự kết hợp giữa nồng độ chất ô nhiễm và động lực học khí quyển.

Nhận diện hướng vận chuyển ô nhiễm (Pollution Rose)

Biểu đồ hoa gió ô nhiễm (*Pollution Rose*) tích hợp thông tin về nồng độ PM2.5, hướng gió và tần suất xuất hiện để xác định các hành lang vận chuyển chất ô nhiễm chủ đạo.

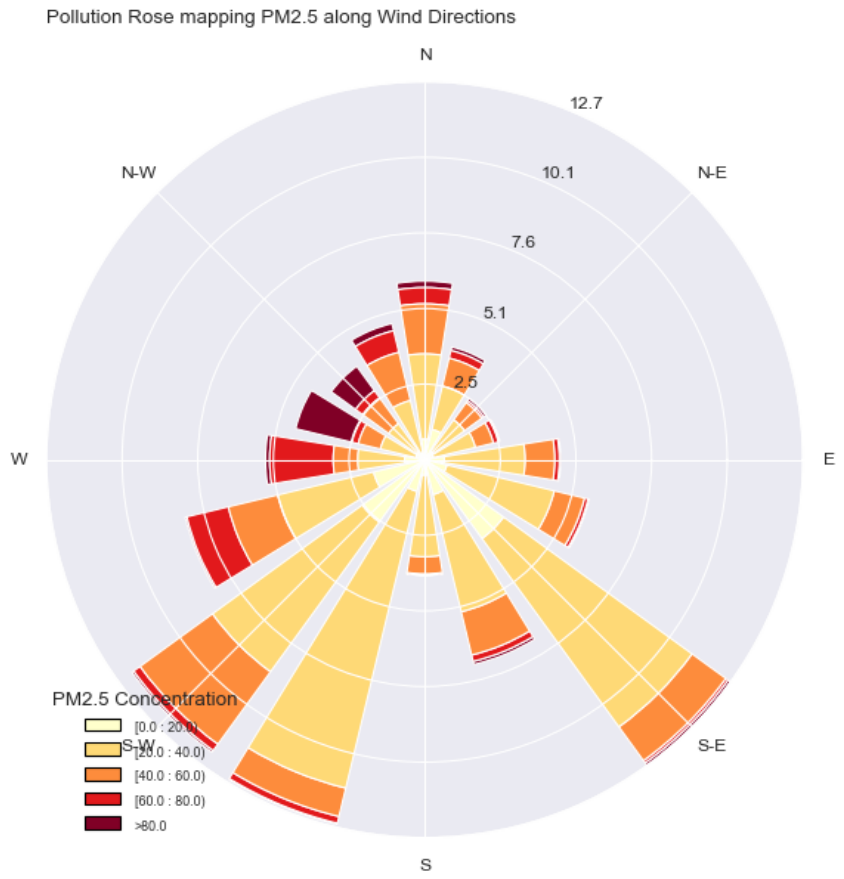

Figure 3.16: Biểu đồ Pollution Rose thể hiện nồng độ PM2.5 theo hướng gió

Kết quả phân tích cho thấy các sự kiện ô nhiễm nồng độ cao (trên 80 $\mu g/m^3$) có tần suất xuất hiện lớn khi gió thổi từ các hướng Nam và Tây Nam. Điều này cho thấy ảnh hưởng mạnh mẽ của các nguồn thải từ các khu công nghiệp tập trung và hoạt động cảng biển phía Nam thành phố, đóng đóng vai trò là nguồn phát thải liên vùng quan trọng [7].

Phân rã chuỗi thời gian (Time-series Decomposition)

Quá trình phân rã chuỗi thời gian giúp tách biệt các thành phần xu hướng, chu kỳ và nhiễu nhằm hiểu rõ cấu trúc nội tại của dữ liệu bụi mịn.

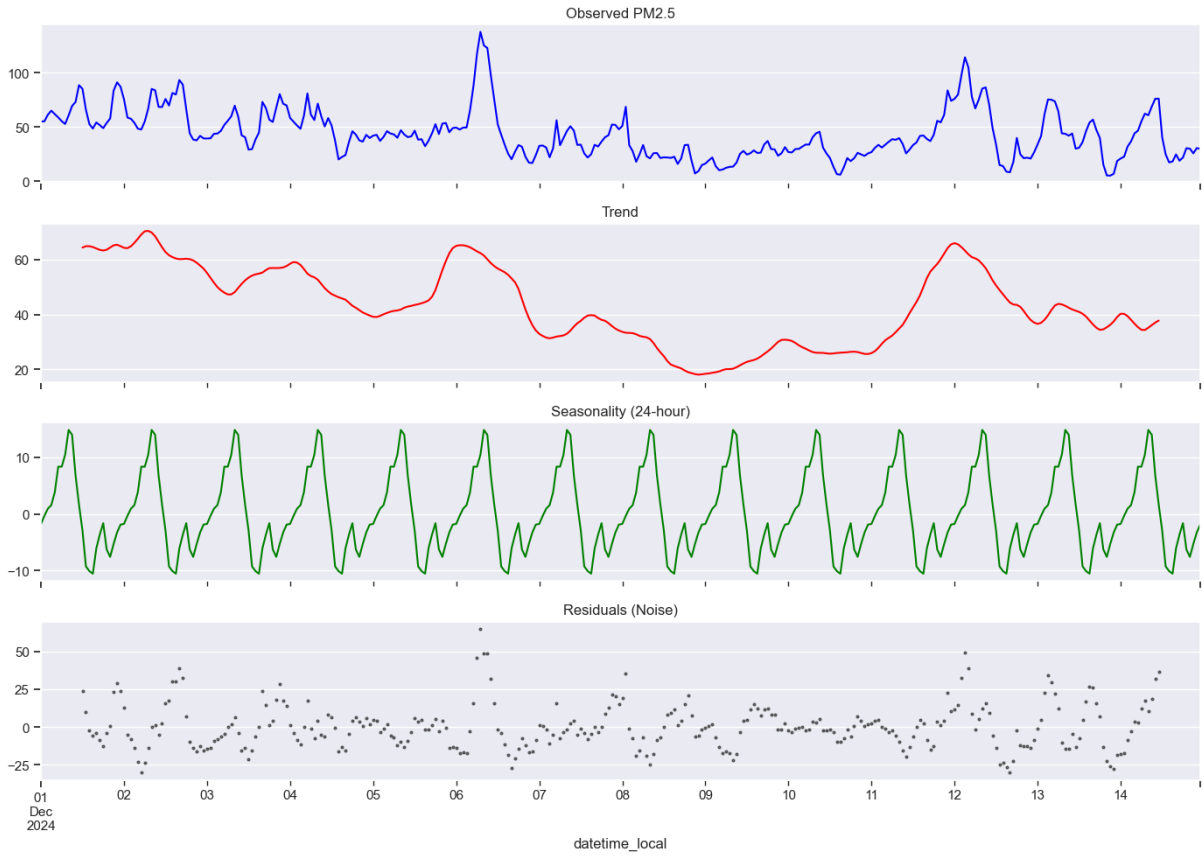

Figure 3.17: Phân rã chuỗi thời gian PM2.5 thành các thành phần Xu hướng, Chu kỳ và Nhiễu

- **Thành phần xu hướng (*Trend*):** Thể hiện sự biến động dài hạn, phản ánh các tác động của điều kiện khí tượng vĩ mô và nhịp độ kinh tế xã hội.
- **Thành phần chu kỳ (*Seasonality*):** Chu kỳ 24 giờ lặp lại rất ổn định, khẳng định sự chi phối tuyệt đối của hoạt động giao thông đô thị và sự co giãn của tầng biên khí quyển (BLH) đối với nồng độ bụi mịn tại bề mặt [11].
- **Thành phần nhiễu (*Residuals*):** Đại diện cho các biến động ngẫu nhiên hoặc các sự kiện ô nhiễm cực đoan không mang tính chu kỳ.

Phân tích tự tương quan (ACF và PACF)

Việc đánh giá tính tự tương quan đóng vai trò nền tảng trong việc thiết lập các tham số cho các mô hình dự báo thống kê và học máy.

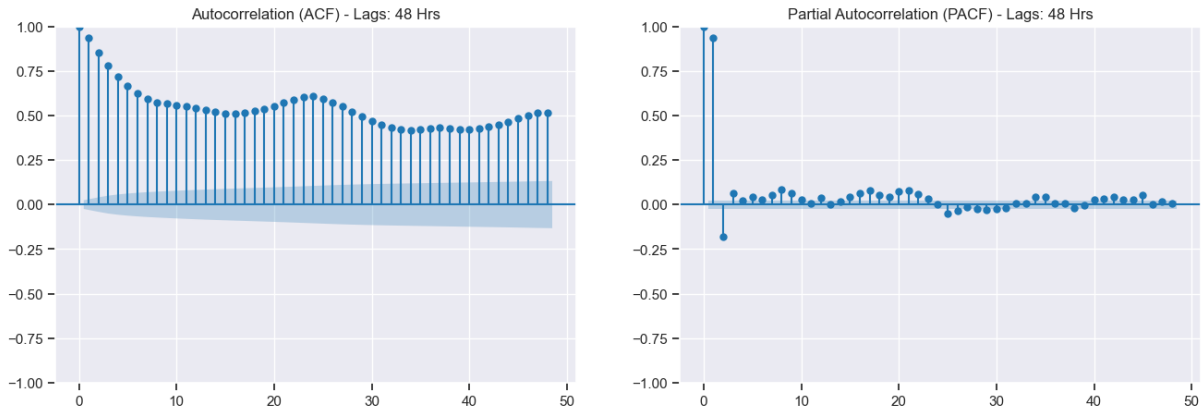

Figure 3.18: Biểu đồ tự tương quan (ACF) và tự tương quan riêng phần (PACF) của chuỗi PM2.5

- **Tự tương quan (ACF):** Hàm ACF giảm chậm (*Slow decay*) và có tính lặp lại sau mỗi 24 giờ. Điều này cho thấy chuỗi dữ liệu có tính "trì trệ" (*Persistence*) rất cao, nghĩa là nồng độ bụi trong quá khứ có ảnh hưởng kéo dài đến các thời điểm tương lai.
- **Tự tương quan riêng phần (PACF):** PACF xuất hiện các hệ số có ý nghĩa thống kê tại các bậc trễ đầu tiên (Lag 1, 2). Kết quả này khẳng định cấu trúc tự hồi quy (*Autoregressive*) mạnh mẽ của dữ liệu, là cơ sở để áp dụng các mô hình ARIMA hoặc các mạng học sâu như LSTM nhằm nắm bắt các phụ thuộc thời gian ngắn hạn và dài hạn [2].

Phân loại chất lượng không khí (AQI Categorization)

Để đánh giá mức độ ảnh hưởng của nồng độ PM2.5 đối với sức khỏe cộng đồng, nghiên cứu thực hiện phân loại dữ liệu huấn luyện theo Quy chuẩn kỹ thuật quốc gia về môi trường của Việt Nam (VN_AQI).

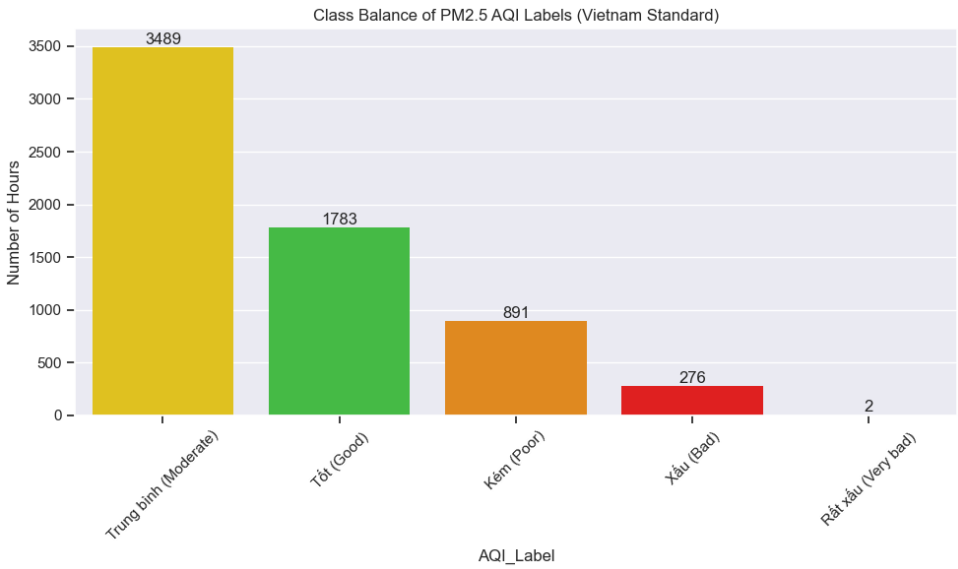

Figure 3.19: Phân bổ các mức chất lượng không khí (AQI) theo tiêu chuẩn Việt Nam trong tập huấn luyện

Kết quả thống kê cho thấy nồng độ PM2.5 tại khu vực nghiên cứu phần lớn thời gian nằm ở ngưỡng "Trung bình" (Moderate - 3.489 giờ) và "Tốt" (Good - 1.783 giờ). Tuy nhiên, số lượng giờ quan trắc ở mức "Kém" (Poor) và "Xấu" (Bad) vẫn chiếm tỷ lệ đáng kể, khẳng định tính cấp thiết của việc dự báo sớm nhằm bảo vệ sức khỏe người dân [7]. Đáng lưu ý, biểu đồ thể hiện sự mất cân bằng lớp (*Class Imbalance*) cực kỳ nghiêm trọng, đặc biệt là ở mức "Rất xấu" (Very Bad) chỉ xuất hiện 2 mẫu. Sự khan hiếm của các dữ liệu ô nhiễm cực đoan trong tập huấn luyện tạo nên rào cản cho mô hình trong việc học các đặc trưng của những sự kiện hiếm gặp nhưng có tác động tiêu cực nhất [2].

3.3.4 Kết luận EDA

Quá trình phân tích dữ liệu khám phá (EDA) trên tập huấn luyện đã cung cấp một bức tranh toàn diện về đặc tính của bụi mịn PM2.5 tại khu vực nghiên cứu, tạo tiền đề vững chắc cho việc xây dựng các mô hình dự báo. Những kết luận chính yếu từ chương này bao gồm:

- **Đặc trưng thống kê và Mối quan hệ giữa các kích cỡ bụi:** Dữ liệu nồng độ bụi thể hiện dạng phân phối lệch phải mạnh với sự hiện diện thường xuyên của các giá trị ngoại lai cực đoan (*outliers*), đòi hỏi các kỹ thuật chuẩn hóa mạnh mẽ trong giai đoạn tiền xử lý. Sự tương quan xấp xỉ tuyệt đối ($r \approx 0.99$) giữa PM2.5, PM1 và UM003 khẳng định tính đồng nhất trong cơ chế phát thải đô thị, đồng thời cho thấy việc tập trung dự báo PM2.5 là hướng tiếp cận đại diện tối ưu [7].

- **Cơ chế chi phối của yếu tố khí tượng:** Thông qua phân tích nhị biến và đa biến, nghiên cứu xác định độ cao tầng biên (BLH) và tốc độ gió là hai nhân tố có ảnh hưởng nghịch biến mạnh mẽ nhất đến nồng độ bụi mịn. Phân tích *Pollution Rose* đã nhận diện được các hành lang vận chuyển ô nhiễm chủ đạo từ hướng Nam và Tây Nam, cho thấy sự ảnh hưởng từ các khu vực phát thải công nghiệp liên vùng. Ngoài ra, vai trò của lượng mưa trong việc lắng đọng ướt cũng được làm rõ, giải thích sự sụt giảm nồng độ đáng kể trong các tháng mùa mưa [10].

- **Tính chất chu kỳ và Cấu trúc thời gian:** Kết quả phân rã chuỗi thời gian (STL) và phân tích ACF/PACF khẳng định chuỗi dữ liệu PM2.5 mang tính chu kỳ 24 giờ ổn định và tính phụ thuộc quá khứ (*Persistence*) cao. Đỉnh ô nhiễm *bimodal* vào sáng sớm và đêm muộn trùng khớp với chu kỳ hoạt động giao thông và sự biến động của tầng biên khí quyển [11]. Những đặc tính này gợi mở việc ứng dụng các mô hình học sâu có khả năng nắm bắt phụ thuộc thời gian như LSTM, GRU hoặc các mô hình thống kê SARIMAX tích hợp biến ngoại sinh.

- **Thách thức về mất cân bằng dữ liệu:** Biểu đồ phân bổ AQI theo tiêu chuẩn Việt Nam cho thấy sự mất cân bằng lớp cực kỳ nghiêm trọng. Việc các lớp "Xấu" và "Rất xấu" chiếm tỷ lệ mẫu rất thấp đặt ra thách thức về độ nhạy (*Recall*) của mô hình. Điều này đòi hỏi các chiến lược huấn luyện đặc thù để đảm bảo khả năng cảnh báo chính xác các sự kiện ô nhiễm cực đoan [2].

Tóm lại, những kết quả thu được từ EDA không chỉ mô tả thực trạng chất lượng không khí mà còn trực tiếp định hướng cho chiến lược lựa chọn đặc trưng (*Feature Selection*) và thiết lập cấu trúc mô hình tối ưu sẽ được triển khai trong chương kế tiếp.

3.4 Tiền xử lý dữ liệu (Preprocessing)

Sau khi hiểu rõ bản chất dữ liệu qua bước EDA, nghiên cứu thiết lập một quy trình tiền xử lý (*Preprocessing Pipeline*) có tính hệ thống cao. Do đặc thù của bài toán dự báo chuỗi thời gian (*Time-series Forecasting*), trình tự các bước được thiết kế chặt chẽ nhằm bảo đảm tính toàn vẹn của dữ liệu và ngăn chặn hiện tượng rò rỉ thông tin (*Data Leakage*). Quy trình bao gồm việc khởi tạo các đặc trưng liên tục trên toàn bộ chuỗi thời gian trước khi thực hiện phân tách tập dữ liệu và lựa chọn đặc trưng. Ngoài ra, tiền xử lý còn được nhánh hóa nhằm đáp ứng các yêu cầu kỹ thuật khác biệt giữa nhóm mô hình dạng cây (*Tree-based*) và nhóm mô hình học sâu (*Deep Learning*).

3.4.1 Kỹ thuật đặc trưng (Feature Engineering)

Việc xây dựng tập đặc trưng (*Feature Pool*) là bước đầu tiên và quan trọng nhất, được thực hiện trên dãy số liệu liên tục nhằm đảm bảo các biến trễ (*Lags*) và thống kê cửa sổ trượt (*Rolling Windows*) không bị đứt gãy. Quy trình này tập trung vào việc mô hình hóa các quy luật vật lý và hành vi đô thị ảnh hưởng đến nồng độ bụi mịn PM2.5 thông qua các nhóm biến số sau:

1. **Đặc trưng thời gian và bối cảnh đô thị:** Trích xuất các thành phần thời gian để mô hình hóa chu kỳ sinh hoạt và tác động của con người:
   - `hour`, `day_of_week`, `month`: Các thành phần thời gian cơ bản mô tả chu kỳ ngày, tuần và năm.
   - `is_weekend`: Biến nhị phân phân loại ngày cuối tuần nhằm nắm bắt sự thay đổi nhịp độ giao thông công nghiệp.
   - `is_rush_hour`: Xác định các khung giờ cao điểm tiêu biểu tại TP.HCM (*7–9h và 17–19h*) gắn liền với phát thải giao thông nội đô.
   - `is_dry_season`: Phân loại mùa tại miền Nam Việt Nam (*tháng 11 đến tháng 4 năm sau*), giai đoạn thường ghi nhận nồng độ bụi cao do ít mưa và khí quyển ổn định.
2. **Mã hóa vòng lặp (Cyclic Encoding):** Biến đổi các đặc trưng có tính chu kỳ sang không gian lượng giác bằng hàm Sin và Cos:
   - `hour_sin`, `hour_cos`: Mã hóa chu kỳ 24 giờ.
   - `month_sin`, `month_cos`: Mã hóa chu kỳ 12 tháng, giúp duy trì tính liên tục (ví dụ: khoảng cách giữa tháng 12 và tháng 1), hỗ trợ hiệu quả cho các mạng nơ-ron học sâu.
3. **Động lực học và Vật lý khí tượng:** Mô hình hóa các cơ chế vận chuyển và lắng đọng chất ô nhiễm:
   - `is_raining`: Chỉ báo trạng thái có mưa dựa trên dữ liệu khí tượng.
   - `hours_since_last_rain`: Tính toán thời gian tích lũy kể từ lần mưa gần nhất để mô tả sự phục hồi nồng độ bụi sau khi bị rửa trôi bởi hiện tượng lắng đọng ướt.

- `wind_u`, `wind_v`: Thành phần vector hóa của gió (tốc độ và hướng) trên trục tọa độ, giúp mô tả chính xác hướng vận chuyển khối khí thay vì sử dụng độ đơn thuần.
- `wind_condition`: Biến định tính phân loại các mức độ tĩnh lặng hoặc lưu động của không khí.
- `pressure_trend_3h`: Biến thiên áp suất trong 3 giờ gần nhất nhằm theo dõi sự ổn định hoặc xáo trộn của các hệ thống khí tượng bề mặt.

4. **Đặc trưng trễ (Lags) và Biến động (Differences):** Tận dụng đặc tính trì trệ (*Persistence*) và dữ liệu quá khứ:
   - `pm25_lag_[1, 2, 3, 6, 12, 24, 48, 72]`: Giá trị nồng độ bụi tại các bậc trễ khác nhau, cung cấp thông tin về trạng thái không khí trong tối đa 3 ngày trước thời điểm dự báo.
   - `pm25_diff_1h`, `pm25_diff_24h`: Tốc độ thay đổi nồng độ bụi so với 1 giờ và 24 giờ trước đó nhằm nắm bắt quán tính của chuỗi thời gian.
5. **Thống kê cửa sổ trượt (Rolling Statistics):** Nắm bắt xu hướng nồng độ bụi qua các quy mô thời gian khác nhau (*6h, 12h, 24h, 48h, 72h*):
   - `pm25_roll_[window]_mean`: Trung bình trượt, giúp loại bỏ nhiễu cục bộ và nhận diện nồng độ nền trong khu vực.
   - `pm25_roll_[window]_std`: Độ lệch chuẩn trượt, phản ánh mức độ biến động cường độ mạnh hay yếu của chất ô nhiễm trong từng giai đoạn.

3.4.2 Phân chia dữ liệu (Train/Val/Test Split)

Để đánh giá chính xác khả năng tổng quát hóa của các mô hình dự báo, nghiên cứu thực hiện phân tách tập dữ liệu theo trình tự thời gian nghiêm ngặt (*Chronological Split*). Phương pháp này đảm bảo tuân thủ nguyên tắc thực tiễn trong dự báo chuỗi thời gian: mô hình chỉ được học từ dữ liệu quá khứ và kiểm tra trên dữ liệu tương lai, tránh hiện tượng rò rỉ dữ liệu (*Data Leakage*). Tập dữ liệu bao gồm 10.639 bản ghi được phân chia theo tỷ lệ kinh nghiệm **60% – 20% – 20%** cho các giai đoạn huấn luyện, kiểm định và kiểm tra cuối cùng:

- **Tập huấn luyện (Training Set):** Bao gồm 6.383 mẫu (chiếm 60%), kéo dài từ ngày 22/11/2024 đến ngày 15/08/2025. Đây là tập dữ liệu nền tảng để các thuật toán học hỏi các quy luật biến động chu kỳ và tương quan khí tượng.
- **Tập kiểm định (Validation Set):** Bao gồm 2.128 mẫu (chiếm 20%), kéo dài từ ngày 15/08/2025 đến ngày 12/11/2025. Tập này đóng vai trò quan trọng trong việc tinh chỉnh siêu tham số (*Hyperparameter Tuning*) và lựa chọn mô hình tối ưu.
- **Tập kiểm tra (Testing Set):** Bao gồm 2.128 mẫu (chiếm 20%), kéo dài từ ngày 12/11/2025 đến ngày 09/02/2026. Tập dữ liệu này được giữ hoàn toàn độc lập và chỉ được sử dụng để đánh giá hiệu năng thực tế của các mô hình trong giai đoạn cuối cùng.

Việc phân tách này cũng cho thấy tính thử thách của bài toán, khi tập Testing rơi vào giai đoạn cuối năm và đầu năm mới — thời điểm đỉnh điểm của mùa khô tại TP.HCM với các sự kiện ô nhiễm không khí phức tạp nhất.

3.4.3 Phân tích và Lựa chọn đặc trưng (Feature Selection)

Với một tập hợp đặc trưng phong phú được khởi tạo, nghiên cứu tiếp tục thực hiện quy trình lựa chọn đặc trưng (*Feature Selection*) nhằm tối ưu hóa không gian tham số và giảm thiểu rủi ro quá khớp. Để đảm bảo tính khách quan, mọi quyết định lựa chọn đều dựa trên các phân tích thống kê thực hiện trên tập Huấn luyện.

Loại bỏ các đặc trưng dựa trên kiến thức miền và EDA

Một số nhóm đặc trưng được loại bỏ dựa trên các phân tích định lượng ở chương trước nhằm tinh gọn tập dữ liệu:

- **Đa cộng tuyến và rò rỉ thông tin:** Loại bỏ `pm1` và `um003` do tương quan gần như tuyệt đối với biến mục tiêu ($r \approx 0.99$). Việc giữ lại các biến này có thể dẫn đến hiện tượng đa cộng tuyến (*Multicollinearity*), khiến mô hình đưa ra các dự báo dựa trên nồng độ hạt thay vì học các quy luật vận chuyển hạt bụi.
- **Dữ liệu nhiễu và dư thừa:** Các biến khí tượng từ trạm OpenAQ (`temperature`, `relativehumidity`) bị loại bỏ do trùng lặp với nguồn Open-Meteo nhưng chứa nhiều nhiễu cảm biến cục bộ.
- **Biến đổi định hướng:** `wind_direction_10m` bị loại bỏ để ưu tiên sử dụng các thành phần vector `wind_u` và `wind_v`, giúp giải quyết vấn đề không liên tục của vòng chia độ.

Chiến lược xếp hạng đặc trưng lai (Hybrid Ranking Strategy)

Nghiên cứu áp dụng phương pháp xếp hạng tầm quan trọng của các đặc trưng thông qua sự kết hợp giữa hai mô hình học máy: **Random Forest** (dựa trên mức giảm *Impurity*) và **XGBoost** (dựa trên thông tin *Gain*). Do mỗi mô hình có cơ chế tính toán và thang đo tầm quan trọng khác nhau, nghiên cứu thực hiện chuẩn hóa thứ tự ưu tiên của từng mô hình bằng kỹ thuật Min–Max trước khi tính toán **Thứ hạng trung bình (Mean Rank)**. Các đặc trưng có giá trị *Mean Rank* thấp nhất (tương ứng với độ quan trọng cao nhất) sẽ được ưu tiên lựa chọn.

Lựa chọn tập K-đặc trưng và Bảo lưu các biến trễ then chốt

Quy trình lựa chọn cuối cùng được thiết lập theo cơ chế **Top-K + Forced Inclusion**:

1. Lựa chọn **Top-25** đặc trưng có thứ hạng trung bình tốt nhất từ phân tích trên.
2. Áp dụng cơ chế bảo lưu (*Forced Inclusion*) để đảm bảo sự hiện diện của các biến trễ PACF quan trọng gồm `pm25_lag_1`, `pm25_lag_2` và `pm25_lag_24`. Đây là các biến mang thông tin về "bộ nhớ" ngắn hạn và chu kỳ ngày đêm của chuỗi thời gian đã được khẳng định qua bước EDA.

Kết quả phân tích tầm quan trọng của các đặc trưng thông qua mô hình Random Forest và XGBoost đã mang lại những nhận định quan trọng phản ánh bản chất của dữ liệu:

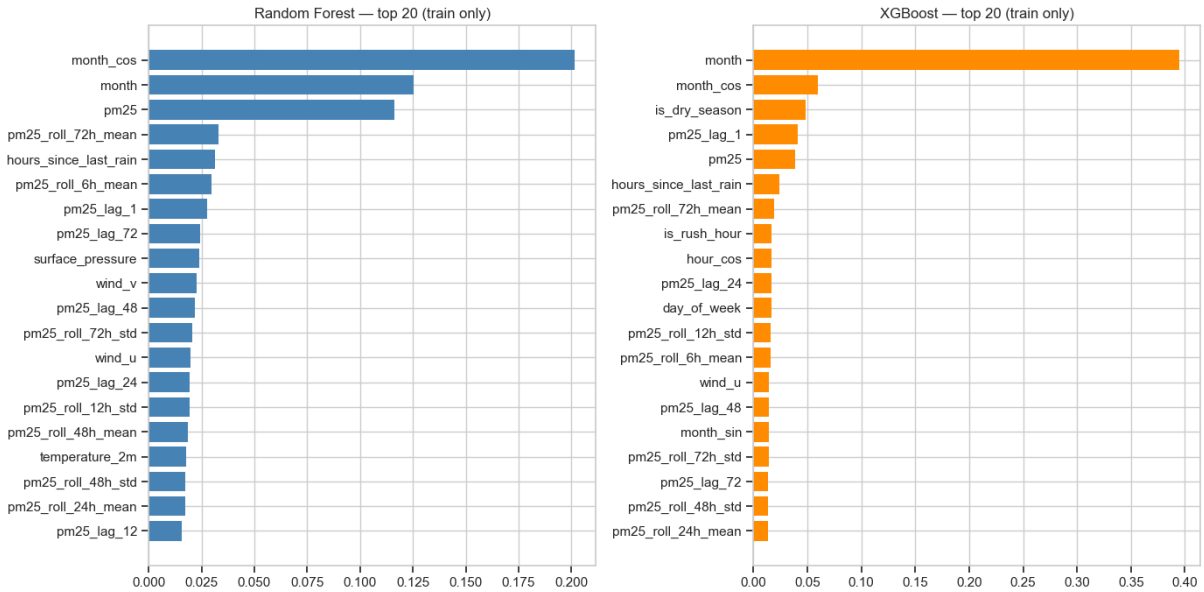

Figure 3.20: So sánh tầm quan trọng của các đặc trưng giữa Random Forest và XGBoost

- **Sự thống trị của tính mùa vụ:** Các biến `month` và `month_cos` đứng đầu bảng xếp hạng ở cả hai mô hình. Điều này khẳng định chu kỳ năm và sự phân hóa mùa khô/mưa là nhân tố then chốt chi phối nồng độ PM2.5 tại khu vực nghiên cứu.

- **Tính trì trệ của chuỗi thời gian:** Nồng độ hiện tại (`pm25`) và các biến trễ gần nhất (`pm25_lag_1`) giữ thứ hạng rất cao, minh chứng cho tính tự tương quan mạnh mẽ của nồng độ chất ô nhiễm.

- **Vai trò của các yếu tố vật lý:** Đặc trưng `hours_since_last_rain` xuất hiện trong nhóm 5 đặc trưng quan trọng nhất theo xếp hạng tổng hợp. Điều này cho thấy mô hình đã nắm bắt thành công cơ chế "rửa trôi" của mưa và sự tích lũy trở lại của bụi mịn. Ngoài ra, các thành phần vector gió (`wind_u`, `wind_v`) cũng đóng góp đáng kể cho việc giải thích hướng phát tán ô nhiễm.

- **Hiệu quả của đặc trưng cửa sổ trượt:** Các biến trung bình trượt (`pm25_roll_72h_mean`, `pm25_roll_6h_mean`) có thứ hạng cao, giúp mô hình nhận diện được xu hướng nồng độ nền (*Background concentration*) thay vì chỉ dựa vào các giá trị tức thời có độ nhiễu cao.

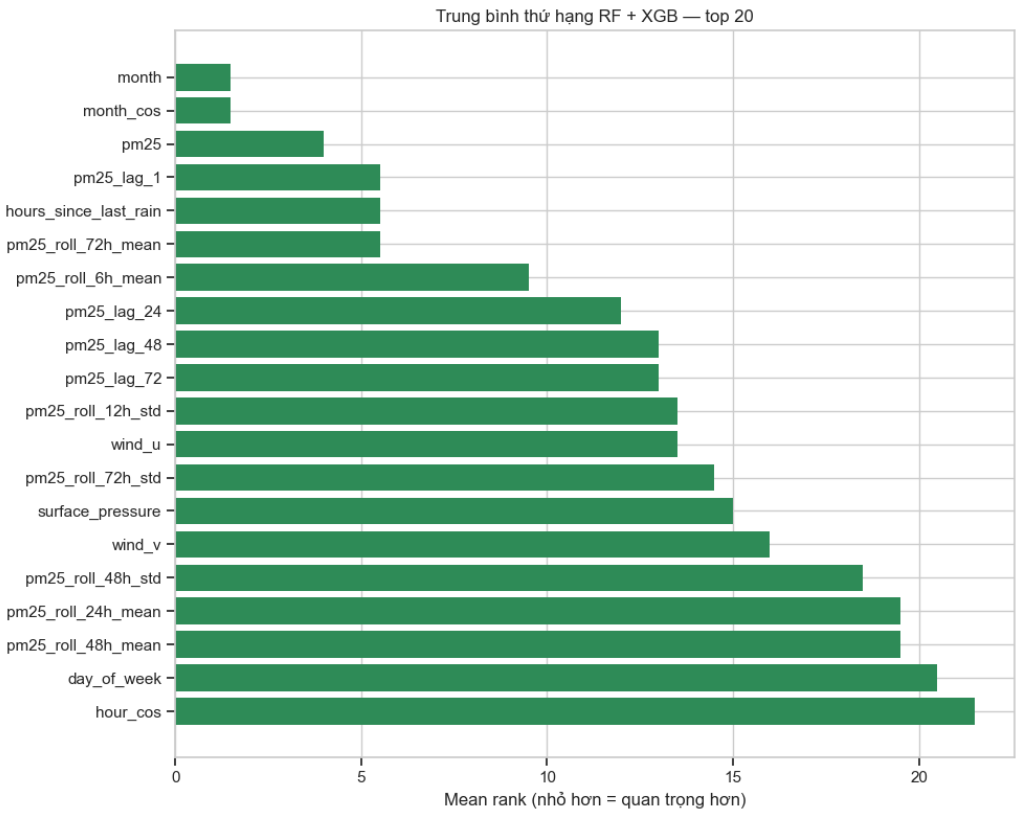

Figure 3.21: Top 20 đặc trưng quan trọng nhất dựa trên Thứ hạng trung bình (Mean Rank)

Việc kết hợp đa dạng các nhóm đặc trưng từ thời gian, khí lượng đến các thông số chuỗi thời gian đảm bảo tập dữ liệu đầu vào có đầy đủ thông tin để mô hình thực hiện dự báo trong các điều kiện khí quyển biến động.

3.4.4 Biến đổi và Chuẩn hóa dữ liệu (Scaling & Transformation)

Bước cuối cùng trong quy trình tiền xử lý là chuẩn hóa dữ liệu nhằm đáp ứng các yêu cầu kỹ thuật khắt khe của nhóm mô hình học sâu và mô hình thống kê. Khác với nhóm mô hình dạng cây có đặc tính không nhạy cảm với thang đo, các mạng nơ-ron học sâu (như LSTM, GRU) đòi hỏi dữ liệu đầu vào phải được biến đổi về một không gian phân phối ổn định để tối ưu hóa quá trình hội tụ của thuật toán luyện.

1. **Biến đổi Logarit (Log-Transformation):** Do nồng độ PM2.5 có phân phối lệch phải mạnh với nhiều giá trị ngoại lai, nghiên cứu áp dụng hàm biến đổi `log1p` ($y = \ln(1 + x)$) cho biến mục tiêu và toàn bộ nhóm đặc trưng có liên quan (`pm25`, các biến trễ, trung bình trượt). Kỹ thuật này giúp ổn định phương sai (*Variance Stabilization*) và thu hẹp tầm ảnh hưởng của các giá trị ô nhiễm cực đoan, giúp mô hình nắm bắt tốt hơn các quy luật dài hạn.

2. **Chuẩn hóa Z-score (Standardization):** Toàn bộ ma trận đặc trưng sau khi biến đổi logarit được đưa qua bộ chuẩn hóa *StandardScaler*. Kỹ thuật này đưa dữ liệu về dạng có trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này đảm bảo rằng các trọng số trong mô hình được cập nhật đồng đều cho tất cả các nhóm biến số, tránh

việc các biến khí tượng (thang đo nhỏ) bị lấn át bởi các biến nồng độ (thang đo lớn).

3. **Nguyên tắc ngăn chặn rò rỉ và Khả năng hoàn tác:** Bộ chuẩn hóa chỉ được tính toán (*fit*) duy nhất trên tập Huấn luyện. Các tham số thu được được bảo lưu để thực hiện quy trình chuyển đổi (*transform*) cho các tập dữ liệu còn lại. Đồng thời, các tham số này cũng được sử dụng cho quá trình hoàn tác (*Inverse Transformation*) bằng hàm `expm1` để đưa kết quả dự báo từ không gian logarit trở lại thang đo nồng độ gốc ($\mu g/m^3$) phục vụ giai đoạn đánh giá hiệu năng chính xác.

Tóm lại, thông qua quy trình tiền xử lý dữ liệu có hệ thống từ xây dựng đặc trưng đến chuẩn hóa chuyên sâu, nghiên cứu đã thiết lập được một nền tảng dữ liệu vững chắc, sẵn sàng cho giai đoạn huấn luyện và so sánh hiệu năng các mô hình dự báo trong các chương tiếp theo.

Chapter 4

HUẤN LUYỆN VÀ TỐI ƯU HÓA MÔ HÌNH (MODEL TRAINING)

Dựa trên tập đặc trưng đã được tối ưu hóa từ chương trước, nghiên cứu tiến hành huấn luyện các mô hình dự báo nồng độ PM2.5 cho khung thời gian 24 giờ tới ($t + 24$). Quy trình được thực hiện qua hai giai đoạn: thiết lập mô hình cơ sở (Baseline) và tối ưu hóa siêu tham số chuyên sâu.

4.1 Thiết lập mô hình cơ sở (Baseline Models)

Giai đoạn đánh giá Baseline nhằm xác định năng lực dự báo tiềm năng của các kiến trúc thuật toán khi sử dụng các thiết lập tham số mặc định hoặc tiêu chuẩn.

4.1.1 Nhóm mô hình học máy dạng cây (Tree-based Models)

Nghiên cứu lựa chọn ba thuật toán Ensemble Learning phổ biến dựa trên cấu trúc cây quyết định để làm mô hình cơ sở. Các mô hình này được huấn luyện trên tập dữ liệu nguyên bản (original scale) do đặc tính không nhạy cảm với thang đo của cấu trúc phân nhánh:

- **Random Forest (RF):** Sử dụng cơ chế *Bagging* với 200 thực thể cây (`n_estimators`) và độ sâu tối đa 20 lớp nhằm kiểm soát khả năng học thuộc lòng của mô hình.
- **XGBoost (XGB):** Thuật toán *Gradient Boosting* sử dụng phương pháp biểu đồ (*Histogram method*) để tăng tốc độ huấn luyện và thực hiện lấy mẫu đặc trưng ngẫu nhiên (`colsample_bytree`) ở mức 0.9.
- **LightGBM (LGBM):** Một biến thể Boosting tối ưu về hiệu năng tính toán, sử dụng chiến lược phát triển cây theo chiều sâu lá (*Leaf-wise*) với tốc độ học $\eta = 0.05$.

Kết quả đánh giá trên tập Kiểm tra (Testing set) được tổng hợp trong Bảng 4.1 và Hình 4.1.

Table 4.1: Hiệu năng của các mô hình Tree-based Baseline trên tập Kiểm tra

Mô hình	**RMSE** ($\mu g/m^3$)	**MAE** ($\mu g/m^3$)	**MAPE** (%)
Random Forest	21,12	15,08	44,76
XGBoost	**19,93**	**14,67**	**42,92**
LightGBM	20,38	14,89	43,46

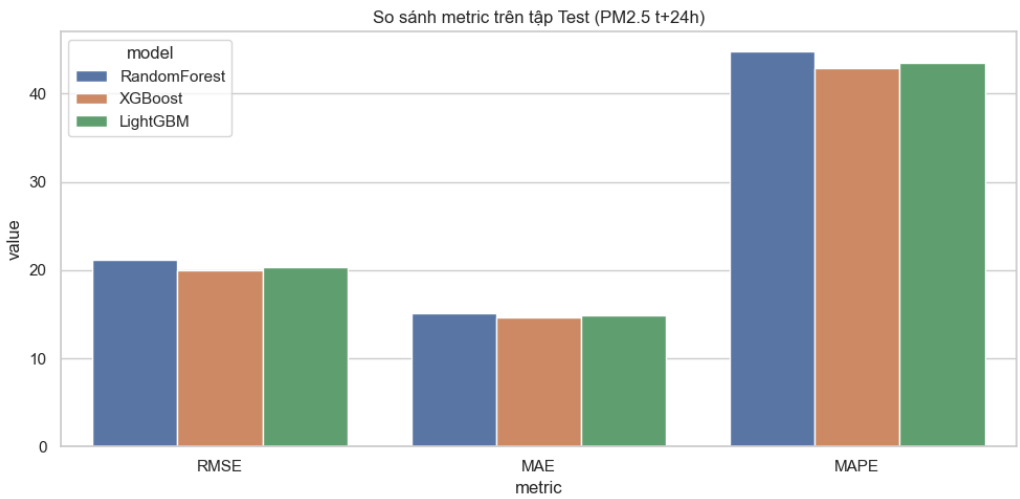

Figure 4.1: So sánh các chỉ số sai số của nhóm mô hình Tree-based Baseline

Kết quả sơ bộ cho thấy **XGBoost** thể hiện khả năng dự báo vượt trội nhất ngay cả khi chưa qua tinh chỉnh siêu tham số. Tuy nhiên, sai số MAPE ở mức trên 40% cho thấy các thiết lập mặc định chưa đủ để mô hình phản ứng linh hoạt với các sự kiện ô nhiễm không khí phức tạp, đặt ra nhu cầu về một quy trình tối ưu hóa chuyên sâu hơn ở giai đoạn sau.

4.1.2 Nhóm mô hình thống kê (Statistical Models)

Khác với nhóm mô hình cây, các mô hình thống kê trong nghiên cứu này tập trung vào việc mô hình hóa cấu trúc tự tương quan (*Auto-correlation*) và các thành phần mùa vụ của chuỗi thời gian. Nghiên cứu thực hiện đánh giá bốn biến thể gồm ARIMA, SARIMA và các phiên bản mở rộng với biến ngoại sinh (ARIMAX, SARIMAX).

Cấu hình và Tham số cơ sở

Để thiết lập vạch xuất phát, các mô hình được cấu hình với các tham số bậc tự hồi quy (p, P), bậc trung bình trượt (q, Q) và tính mùa vụ ($s = 24$) nhằm tương ứng với chu kỳ thay đổi theo giờ của PM2.5:

- **ARIMA:** Sử dụng cấu hình cơ bản $(1, 1, 1)$ làm nền tảng, tập trung vào khả năng tự hồi quy và xử lý tính không dừng thông qua lấy sai phân bậc 1.
- **SARIMA:** Mở rộng từ ARIMA với thành phần mùa vụ $(1, 0, 0)_{24}$, giúp mô hình ghi nhớ các quy luật lặp lại hàng ngày (chu kỳ 24 giờ) của PM2.5.

- **ARIMAX/SARIMAX:** Tích hợp thêm các biến ngoại sinh (*Exogenous*) bao gồm top 5 đặc trưng khí tượng (như vận tốc gió, độ ẩm, áp suất) đã qua chọn lọc từ quy trình Feature Selection để cung cấp thêm các tín hiệu vật lý hỗ trợ dự báo.

Chiến lược Ngăn chặn Rò rỉ Dữ liệu (Data Leakage Prevention)

Trong dự báo chuỗi thời gian, rò rỉ dữ liệu là rủi ro lớn nhất dẫn đến kết quả dự báo "ảo". Nghiên cứu áp dụng quy trình kiểm soát nghiêm ngặt thông qua kỹ thuật **True 24-Step Walk-Forward Forecast**:

- **Cơ chế Dự báo:** Để dự báo cho thời điểm $t + 24$, mô hình chỉ được phép tiếp cận dữ liệu mục tiêu tối đa đến thời điểm t. Toàn bộ giá trị từ $t + 1$ đến $t + 23$ tuyệt đối không xuất hiện trong tập đầu vào (*Endogenous*).
- **Cập nhật Luồng dữ liệu:** Thay vì dự báo tĩnh cho toàn bộ tập Test, nghiên cứu thực hiện vòng lặp rolling. Tại mỗi bước, một quan sát thực tế tại t được `append` vào lịch sử của mô hình để dự báo cho $t + 24$ giờ tiếp sau. Quá trình này không thực hiện huấn luyện lại (`refit=False`) để đảm bảo tính khách quan của tham số Baseline.
- **Đồng bộ ngoại sinh:** Các biến ngoại sinh tại thời điểm dự báo cũng được đảm bảo là các giá trị khả dụng tại thời điểm thực hiện lệnh dự báo.

Kết quả dự báo Baseline

Kết quả thu được sau khi hoàn tác biến đổi Logarit (`expm1`) trên tập Kiểm tra được trình bày trong Bảng 4.2.

Table 4.2: Hiệu năng của các mô hình Thống kê Baseline trên tập Kiểm tra

Mô hình	**RMSE** ($\mu g/m^3$)	**MAE** ($\mu g/m^3$)	**MAPE (%)**
SARIMA	20,38	13,75	**31,08**
ARIMAX	21,84	14,62	36,83
SARIMAX	**18,88**	**13,49**	36,70

Đáng chú ý, mô hình **SARIMAX** cho kết quả RMSE thấp hơn hẳn so với tất cả các mô hình học máy dạng cây ở giai đoạn Baseline. Điều này khẳng định rằng PM2.5 tại TP.HCM mang tính phụ thuộc thời gian rất mạnh và các biến khí tượng đóng vai trò then chốt trong việc hiệu chỉnh các sai số của dự báo thống kê thuần túy.

4.1.3 Nhóm mô hình học sâu (Deep Learning Models)

Để đối chiếu với các phương pháp học máy truyền thống và thống kê, nghiên cứu triển khai hai kiến trúc mạng nơ-ron hồi tiếp (Recurrent Neural Networks - RNN) phổ biến là **LSTM** (Long Short-Term Memory) và **GRU** (Gated Recurrent Unit). Đây là các kiến trúc được thiết kế chuyên biệt để xử lý dữ liệu chuỗi có tính phụ thuộc thời gian phức tạp.

Cấu trúc mạng và Quy trình huấn luyện

Các mô hình được xây dựng trên nền tảng thư viện PyTorch với cấu trúc tinh gọn nhằm thiết lập hiệu năng cơ sở:

- **Cấu trúc lớp:** Mỗi mô hình bao gồm 01 lớp RNN (LSTM hoặc GRU) với 64 đơn vị ẩn (*hidden units*), theo sau là một lớp tuyến tính (*Linear layer*) để chuyển đổi không gian đặc trưng về giá trị dự báo nồng độ bụi đơn nhất.
- **Hình dạng dữ liệu (Input Reshaping):** Ma trận đặc trưng phẳng (đã qua chuẩn hóa Z-score ở Chương 3) được biến đổi thành dạng Tensor 3 chiều với kích thước $(\text{Batch}, 1, \text{Features})$. Cách tiếp cận này cho phép mạng RNN trích xuất thông tin từ tập biến trễ đã được làm phẳng trong quy trình Feature Engineering.
- **Cấu hình huấn luyện:** Sử dụng hàm mất mát MSE (*Mean Squared Error*) và thuật toán tối ưu hóa Adam với tốc độ học truyền thống 0,001. Mô hình thực hiện huấn luyện qua 50 chu kỳ (*epochs*) với kích thước lô 64 để đảm bảo sự hội tụ ổn định của gradient.

Kết quả dự báo Baseline

Hiệu năng của các mô hình học sâu trên tập Kiểm tra (sau khi hoàn tác log) được trình bày trong Bảng 4.3.

Table 4.3: Hiệu năng của các mô hình Deep Learning Baseline trên tập Kiểm tra

Mô hình	**RMSE** ($\mu g/m^3$)	**MAE** ($\mu g/m^3$)	**MAPE** (%)
LSTM	**18,64**	**13,10**	**33,70**
GRU	19,24	13,45	34,55

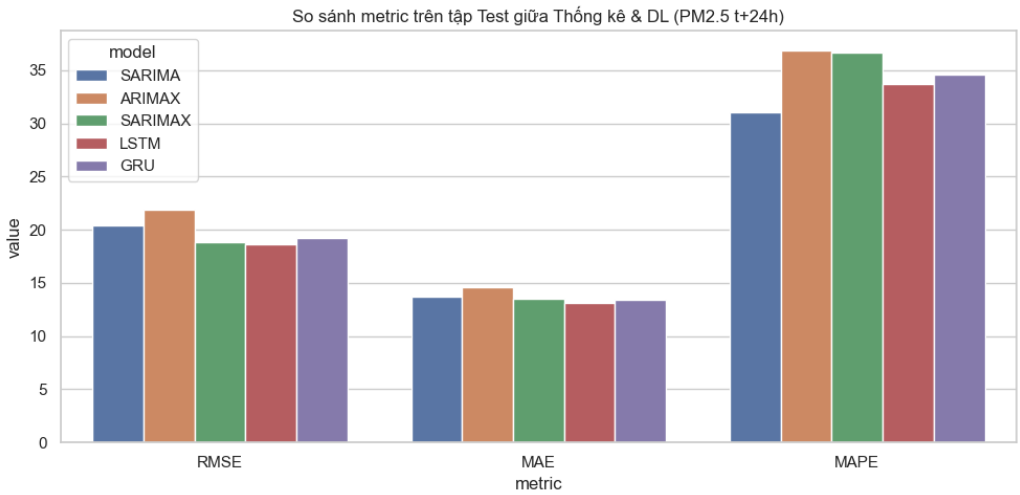

Figure 4.2: So sánh sai số giữa các mô hình Thống kê và Deep Learning cơ sở

LSTM ghi nhận kết quả tốt nhất trong toàn bộ nhóm Baseline (Tree, Stats và DL) với mức RMSE thấp nhất (18,64). Điều này minh chứng cho khả năng vượt trội của kiến trúc Long Short-Term Memory trong việc nắm bắt các phụ thuộc phi tuyến trong chuỗi

thời gian PM2.5. GRU cho kết quả bám đuổi sát sao nhưng chưa tối ưu bằng, có thể do khả năng kiểm soát luồng thông tin qua các cổng (*gates*) của LSTM phù hợp hơn với đặc tính dữ liệu khí tượng đa biến hiện có.

4.2 Chiến lược Tối ưu hóa Siêu tham số (Tuning Strategy)

Sau giai đoạn Baseline, nghiên cứu nhận thấy hiện tượng quá khớp (*Overfitting*) xảy ra nghiêm trọng ở nhóm mô hình cây (sai số tập Huấn luyện thấp hơn gấp nhiều lần các tập còn lại). Do đó, giai đoạn tối ưu hóa tập trung vào việc cân bằng giữa năng lực học và khả năng tổng quát hóa của mô hình thông qua việc rà soát không gian tham số có hệ thống.

4.2.1 Tối ưu hóa nhóm mô hình cây (Tree-based Models)

Quy trình tối ưu hóa được thực hiện thông qua thuật toán tìm kiếm ngẫu nhiên (`RandomizedSearchCV`) kết hợp với cơ chế kiểm định chéo chuỗi thời gian (`TimeSeriesSplit`) với 5 lần lặp (*folds*). Phương pháp này đảm bảo tính nhân quả, tránh việc sử dụng thông tin từ "tương lai" để rà soát tham số. Chiến lược tinh chỉnh tập trung vào cơ chế điều tiết (*Regularization-First*):

- **Kiểm soát độ sâu:** Giới hạn chặt chẽ tham số `max_depth` để tránh việc các cây quyết định chia nhánh quá chi tiết vào các điểm nhiễu.
- **Tăng ngưỡng điều kiện:** Nâng cao các thông số `min_samples_leaf` (cho RF/LGBM) và `min_child_weight` (cho XGB) nhằm yêu cầu mỗi lá cây phải chứa đủ lượng mẫu đại diện nhất định mới được phép phân nhánh.
- **Áp dụng hình phạt trọng số:** Sử dụng các hệ số `reg_alpha` (L_1) và `reg_lambda` (L_2) để trực tiếp triệt tiêu hoặc giảm thiểu trọng số của các đặc trưng ít đóng góp vào phương sai chung.

Không gian rà soát siêu tham số được đề xuất chi tiết trong Bảng 4.4.

Table 4.4: Không gian tìm kiếm siêu tham số cho nhóm mô hình cây

Mô hình	**Tham số tinh chỉnh**	**Miền giá trị tìm kiếm**
Random Forest	`max_depth`	[5, 7, 10, 12, None]
	`min_samples_leaf`	[4, 8, 16, 32]
	`max_features`	[sqrt, log2, 0,5, 0,7]
XGBoost	`learning_rate`	[0,01, 0,03, 0,05, 0,08]
	`max_depth`	[3, 4, 5, 6]
	`reg_alpha / reg_lambda`	[0, 0,1, 1,0, 5,0, 10,0]
	`min_child_weight`	[3, 5, 10, 20]
LightGBM	`num_leaves`	[15, 31, 47, 63]
	`min_child_samples`	[10, 20, 50, 100]
	`colsample_bytree`	[0,6, 0,7, 0,8, 0,9]
	`n_estimators`	[300, 500, 800]

Sau khi tìm được bộ tham số tối ưu thông qua CV trên tập Huấn luyện, mô hình sẽ được huấn luyện lại (*Refit*) trên tập dữ liệu gộp (Huấn luyện + Kiểm thử phát triển) để tận dụng tối đa lượng thông tin trước khi chuyển sang giai đoạn đánh giá cuối cùng.

4.2.2 Tối ưu hóa mô hình thống kê (Statistical Models Tuning)

Việc tối ưu hóa các mô hình họ ARIMA đòi hỏi quy trình tuyển chọn biến dữ liệu và tham số bậc tự hồi quy khắt khe hơn nhằm đảm bảo tính ổn định và ý nghĩa thống kê của các hệ số hồi quy.

Sàng lọc biến ngoại sinh và Kiểm định tính dừng

Đối với các biến thể ARIMAX và SARIMAX, nghiên cứu thực hiện quy trình chọn lọc đặc trưng ngoại sinh (*Exogenous Selection*) qua hai giai đoạn:

- **Tương quan Spearman:** Xác định các biến khí tượng có mối quan hệ đơn điệu mạnh với nồng độ PM2.5 định hướng tương lai.
- **Kiểm định nhân quả Granger (Granger Causality):** Đây là bước then chốt để xác nhận xem các biến khí tượng tại thời điểm t có thực sự mang thông tin tiên lượng cho PM2.5 tại $t + 24$ hay không. Chỉ các biến vượt qua ngưỡng $p < 0,05$ mới được đưa vào ma trận ngoại sinh.
- **Kiểm định ADF:** Áp dụng kiểm định Augmented Dickey-Fuller để xác định bậc sai phân (d), đảm bảo chuỗi trung bình trượt là dừng (*Stationary*) trước khi rà soát các tham số khác.

Thuật toán rà soát Stepwise và Tiêu chuẩn AIC

Do tính chất phức tạp của chu kỳ mùa vụ ($m = 24$), nghiên cứu sử dụng thuật toán tìm kiếm từng bước (*Stepwise Search*) thay vì Grid Search toàn phần để tối ưu hóa thời gian tính toán. Tiêu chuẩn thông tin Akaike (AIC) được chọn làm hàm mục tiêu chính nhằm tìm ra "điểm ngọt" giữa độ chính xác và độ phức tạp của mô hình (Bảng 4.5).

Table 4.5: Không gian rà soát thông số cấu hình dòng ARIMA

Thành phần	**Tham số**	**Miền giá trị rà soát**
Tự hồi quy (Non-seasonal)	p, q	[0, 1, 2, 3]
Sai phân (Differencing)	d	[0, 1] (Dựa trên ADF)
Tự hồi quy (Seasonal)	P, Q	[0, 1, 2]
Chu kỳ mùa vụ	m	24 (Chu kỳ ngày)
Tiêu chuẩn tối ưu	Hàm mục tiêu	Minimize AIC

Sau khi tìm được bộ tham số tối ưu, mô hình được kiểm định phần dư bằng kiểm định **Ljung-Box** để đảm bảo không còn tính tự tương quan thừa, xác nhận mô hình đã khai thác tối đa tín hiệu từ dữ liệu lịch sử.

4.2.3 Tối ưu hóa nhóm mô hình học sâu (Deep Learning Models Tuning)

Khác với các mô hình cây hay thống kê, việc tối ưu hóa nhóm học sâu không chỉ dừng lại ở các tham số số học mà còn mở rộng ra việc tinh chỉnh toàn bộ cấu trúc (*Architecture Search*) của mạng nơ-ron hồi quy.

Kiến trúc Dynamic RNN và Cơ chế học hai chiều

Nghiên cứu thiết lập một cấu trúc mạng linh hoạt (*DynamicRNN*) được xây dựng trên nền tảng PyTorch, cho phép rà soát đồng thời các biến thể kiến trúc khác nhau:

- **Cấu trúc chồng phối (Stacked Layers):** Thử nghiệm việc xếp chồng các lớp RNN để tăng khả năng trích xuất đặc trưng bậc cao.
- **Học hai chiều (Bidirectional RNN):** Cho phép mô hình học các mẫu dữ liệu theo cả chiều thuận và chiều nghịch của chuỗi thời gian, giúp tăng cường khả năng nắm bắt ngữ cảnh cho dữ liệu PM2.5.
- **Lớp giải mã (MLP Decoder):** Phần đầu ra được thiết kế gồm các lớp Tuyến tính (*Linear Layers*) kết hợp với hàm kích hoạt ReLU và Dropout để thực hiện suy luận cuối cùng.

Cơ chế ổn định huấn luyện và Không gian rà soát

Để đảm bảo quá trình hội tụ tối ưu và tránh hiện tượng quá khớp, các "Plugins" trợ giúp huấn luyện được tích hợp (Bảng 4.6):

- **Early Stopping:** Tự động dừng huấn luyện sau 10 Epoch nếu sai số trên tập kiểm thử phát triển không giảm, giúp bảo toàn trạng thái tốt nhất của mô hình.
- **ReduceLROnPlateau:** Cơ chế giảm tốc độ học (*Learning rate*) một cách chủ động khi mô hình rơi vào vùng bão hòa, hỗ trợ việc tìm kiếm cực tiểu toàn cục chính xác hơn.

Table 4.6: Không gian rà soát thông số cấu hình mạng Deep Learning

Thành phần cấu trúc	**Miền giá trị rà soát**
Loại mạng RNN	[LSTM, GRU]
Số lượng nút ẩn (Hidden Size)	[64, 128]
Số lớp chồng phối (Layers)	[1, 2]
Cơ chế học	[Unidirectional, Bidirectional]
Tỉ lệ Dropout	[0,1, 0,3]
Tốc độ học (Learning Rate)	Khởi đầu 1×10^{-3} (Kết hợp Scheduler)
Chống quá khớp (Weight Decay)	1×10^{-5} (L_2 Regularization)

Chapter 5

ĐÁNH GIÁ VÀ TỐI ƯU HÓA KẾT QUẢ (EVALUATION & OPTIMIZATION)

Chương này tập trung vào việc công bố các kết quả thực nghiệm sau quá trình tối ưu hóa siêu tham số, đồng thời tiến hành đối sánh định lượng giữa cấu hình cơ sở (*Baseline*) và cấu hình tối ưu (*Tuned*). Qua đó, nghiên cứu sẽ xác định mức độ cải thiện hiệu năng và lựa chọn mô hình dự báo nồng độ bụi PM2.5 tốt nhất cho khu vực TP. Hồ Chí Minh.

5.1 Kết quả thực nghiệm sau tối ưu hóa

5.1.1 Nhóm mô hình cây (Tree-based Models)

Sau quá trình rà soát bằng *RandomizedSearchCV* kết hợp với chiến lược ngăn chặn quá khớp (*Early Regularization*), bộ siêu tham số tốt nhất cho cả ba thuật toán đã được xác lập (Bảng 5.1).

Table 5.1: Cấu hình siêu tham số tốt nhất cho nhóm mô hình cây

Mô hình	**Tham số tối ưu**	**Giá trị**
Random Forest	`n_estimators`	500
	`max_depth`	5
	`min_samples_leaf`	8
	`max_features`	0.5
	`min_impurity_decrease`	0.05
XGBoost	`n_estimators`	500
	`learning_rate`	0.01
	`max_depth`	3
	`reg_lambda` (L2)	5.0
	`min_child_weight`	10
	`subsample` / `colsample`	0.9 / 0.9
	`gamma`	1.0
LightGBM	`n_estimators`	300
	`learning_rate`	0.01
	`num_leaves`	15
	`max_depth`	-1 (Không giới hạn)
	`reg_alpha` / `reg_lambda`	1.0 / 5.0
	`min_child_samples`	10
	`subsample` / `colsample`	0.8 / 0.9

Hiệu năng của các mô hình sau khi tinh chỉnh được cải thiện đáng kể về khả năng tổng quát hóa trên dữ liệu chưa thực nghiệm (Tập Test). So sánh với giai đoạn Baseline, sai số RMSE đã giảm ổn định, đồng thời hiện tượng quá khớp (vốn là nhược điểm lớn nhất của nhóm cây) đã được kiểm soát hiệu quả (Bảng 5.2).

Table 5.2: Đối sánh hiệu năng trên tập Test dữ liệu thực tế (Baseline vs. Tuned)

Mô hình	**RMSE (Test)**		**MAPE (%)**		**% Cải thiện**
	Baseline	**Tuned**	**Baseline**	**Tuned**	
Random Forest	21.122	18.794	39.75	38.72	11.02%
XGBoost	19.996	**17.731**	38.16	**36.35**	11.33%
LightGBM	20.378	17.975	38.56	36.87	11.79%

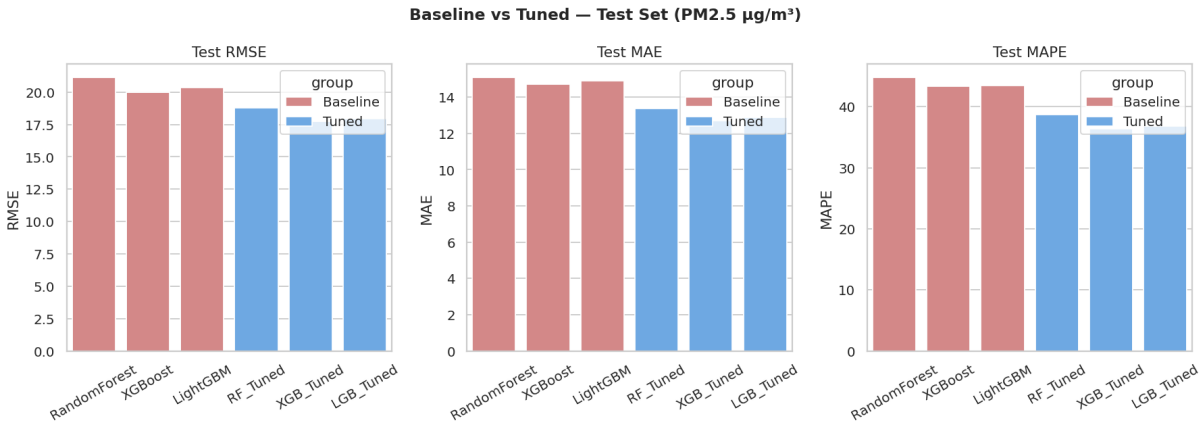

Figure 5.1: Đối sánh trực quan các chỉ số sai số giữa mô hình Baseline và Tuned

Kết quả trực quan tại Hình 5.1 khẳng định tính nhất quán trong việc cải thiện hiệu năng. Đặc biệt, phân tích sâu về hiện tượng quá khớp (Hình 5.2) cho thấy một bước tiến lớn trong phương pháp luận của nghiên cứu.

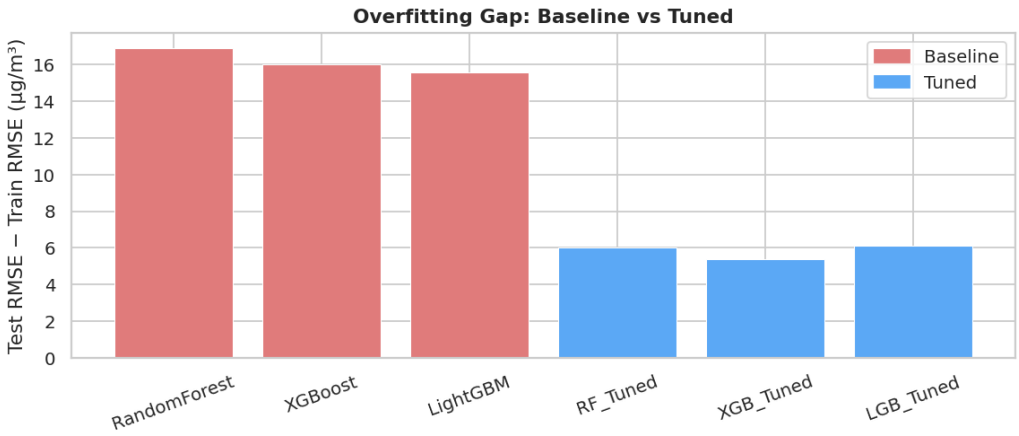

Figure 5.2: Độ chênh lệch sai số giữa tập Huấn luyện và Kiểm tra (Overfitting Gap)

Ở phiên bản Baseline, các mô hình cây gặp vấn đề "học thuộc lòng" dữ liệu huấn luyện dẫn đến khoảng cách sai số giữa tập Train và Test lên đến hơn $16\mu g/m^3$. Nhờ chiến lược tối ưu hóa tập trung vào điều tiết (*Regularization*), khoảng cách này đã được thu hẹp xuống mức dưới $6\mu g/m^3$ ở các phiên bản Tuned. Điều này không chỉ làm giảm RMSE tổng thể mà còn tăng độ tin cậy của mô hình khi triển khai dự báo thực tế, nơi dữ liệu luôn biến động và khác biệt so với quá khứ.

5.1.2 Nhóm mô hình thống kê (Statistical Models)

Đối với nhóm mô hình họ ARIMA, quá trình tối ưu hóa được thực hiện qua hai giai đoạn chính: (1) Sàng lọc các biến ngoại sinh (*Exogenous features*) dựa trên kiểm định thống kê chuyên sâu và (2) Rà soát siêu tham số $(p, d, q)(P, D, Q, m)$ bằng tiêu chuẩn thông tin AIC.

Kết quả kiểm định *Granger Causality* ($p < 0.05$) đã xác nhận 05 biến khí tượng và thời gian mang tín hiệu dự báo sớm cho nồng độ PM2.5, bao gồm: `month_cos`, `surface_pressure`, `is_dry_season`, `wind_u`, và `month`. Các biến này sau đó được đưa

vào mô hình dưới dạng các chuỗi ngoại sinh để hỗ trợ dự báo. Bộ tham số tối ưu thu được từ thuật toán Stepwise AIC được trình bày tại Bảng 5.3.

Table 5.3: Cấu hình siêu tham số tối ưu cho mô hình nhóm Thống kê

Mô hình	**Tham số (p,d,q)**	**Tham số mùa (P,D,Q,m)**
ARIMA	(2, 1, 1)	Không áp dụng
SARIMA	(2, 1, 1)	(1, 0, 0, 24)
ARIMAX	(2, 1, 1)	Không áp dụng
SARIMAX	**(2, 1, 1)**	**(1, 0, 1, 24)**

Bảng 5.4 cho thấy sự cải thiện rõ rệt về hiệu năng khi chuyển đổi từ các cấu hình ARIMA đơn giản sang SARIMAX có tích hợp các yếu tố mùa vụ và ngoại sinh.

Table 5.4: Kết quả thực nghiệm nhóm mô hình Thống kê trên tập Test

Mô hình	**RMSE (Tuned)**	**MAE (Tuned)**	**MAPE (%)**	**Cải thiện v/s Baseline**
ARIMA	18.7909	13.2711	34.81%	10.71%
ARIMAX	18.7623	13.3715	34.98%	10.19%
SARIMA	18.4077	12.8573	33.55%	10.92%
SARIMAX	**17.3994**	**11.9630**	**30.98%**	**15.45%**

Việc bổ sung đồng thời thành phần chu kỳ $m = 24$ và các biến ngoại sinh đã giúp mô hình **SARIMAX** đạt được hiệu năng ấn tượng nhất trong nhóm. Mức cải thiện 15.45% so với cấu hình Baseline cho thấy việc mô hình hóa các yếu tố môi trường kết hợp với chu kỳ 24 giờ là hướng đi đúng đắn nhằm giảm thiểu sai số dự báo trung hạn.

5.1.3 Nhóm mô hình học sâu (Deep Learning Models)

Trong nhóm học sâu, cấu trúc mạng không chỉ dừng lại ở việc chọn lựa tham số mà còn mở rộng ra việc tìm kiếm kiến trúc (*Architecture Search*). Quá trình rà soát lưới (*Grid Search*) đã được thực hiện trên 32 cấu hình khác nhau, xoay quanh các yếu tố: loại tế bào RNN (LSTM/GRU), số lượng nút ẩn, độ sâu của mạng và tính đa hướng (*Bidirectional*).

Kết quả thực nghiệm xác nhận kiến trúc **Bidirectional GRU** với 64 nút ẩn là cấu hình mạnh mẽ nhất (Bảng 5.5). Việc sử dụng mạng hai chiều (*Bidirectional*) giúp mô hình không chỉ học được các tín hiệu từ quá khứ mà còn bảo tồn được các sự phụ thuộc ngữ cảnh dài hạn trong các chuỗi thời gian khí tượng phức tạp.

Table 5.5: Cấu hình siêu tham số tối ưu cho mô hình nhóm Học sâu

Siêu tham số	**Giá trị tối ưu**
Loại mạng RNN	**Bidirectional GRU**
Số lượng nút ẩn (*Hidden units*)	64
Số lượng lớp (*Layers*)	1
Tỉ lệ Dropout	0.1
Optimizer	Adam (Learning Rate = 0.001)
Cơ chế tối ưu	Early Stopping (Patience = 10)

Về mặt hiệu năng, nhóm học sâu cho thấy khả năng phục hồi sai số cực tốt so với các thiết lập cơ bản. Đặc biệt, sai số MAPE đã giảm xuống mức thấp nhất trong các nhóm mô hình, cho thấy khả năng xử lý các điểm dữ liệu cực trị (ô nhiễm nặng) ổn định hơn (Bảng 5.6).

Table 5.6: Kết quả thực nghiệm nhóm mô hình Học sâu trên tập Test

Mô hình	**RMSE (Tuned)**	**MAE (Tuned)**	**MAPE (%)**	**Cải thiện v/s Baseline**
LSTM	18.0215	12.4431	31.52%	13.80%
Bi-GRU	**17.7992**	**12.1730**	**30.41%**	**14.01%**

Sự thành công của cấu trúc **Bidirectional GRU** khẳng định rằng dữ liệu nồng độ bụi PM2.5 mang đặc tính phi tuyến tính cao và phụ thuộc chặt chẽ vào các trạng thái khí tượng liên tục. Việc mạng Neural có thể "nhìn" chuỗi dữ liệu theo cả hai chiều đã giúp tối ưu hóa việc trích xuất đặc trưng từ các biến ngoại sinh như hướng gió và áp suất.

5.2 Đề xuất mô hình kết hợp (Hybrid Model)

Mặc dù các mô hình học sâu (như Bi-GRU) mạnh trong việc bắt các mẫu phi tuyến và các mô hình thống kê (như SARIMAX) mạnh trong việc giải thích tính mùa vụ, mỗi loại đều có những hạn chế riêng khi hoạt động độc lập. Nghiên cứu này đề xuất một kiến trúc kết hợp dựa trên nguyên lý **Residual Learning** (Học sai số) nhằm khai thác tối đa ưu điểm của cả hai phương pháp.

5.2.1 Kiến trúc mô hình SARIMAX-GRU

Mô hình Hybrid được xây dựng qua hai giai đoạn:

- **Giai đoạn 1 (Linear Stage):** Sử dụng mô hình SARIMAX tối ưu đã được tinh chỉnh ở mục 5.1.2 để thực hiện dự báo. Kết quả từ giai đoạn này sẽ đại diện cho phần tuyến tính và tính chu kỳ của dữ liệu. Sai số (Residual) được tính bằng công thức: $\epsilon_t = y_t - \hat{y}_{SARIMAX}$.
- **Giai đoạn 2 (Non-linear Stage):** Một mạng GRU hai chiều (Bi-GRU) được huấn luyện để dự báo riêng phần sai số ϵ_t này dựa trên các biến ngoại sinh và các giá trị trễ.
- **Kết hợp cuối cùng:** Dự báo cuối cùng của mô hình Hybrid là tổng của hai thành phần: $\hat{y}_{Hybrid} = \hat{y}_{SARIMAX} + \hat{\epsilon}_{GRU}$.

5.2.2 Hiệu năng mô hình Hybrid

Việc cho phép mạng GRU tập trung hoàn toàn vào việc giải quyết những "nhiễu" mà SARIMAX không thể bắt được đã mang lại kết quả tích cực (Bảng 5.7).

Table 5.7: Đối sánh hiệu năng giữa SARIMAX đơn lẻ và mô hình Hybrid

Mô hình	**RMSE (Test)**	**MAE (Test)**	**MAPE (%)**
SARIMAX (Tuned)	17.3994	11.9630	**30.98%**
Hybrid (SARIMAX+GRU)	**17.2437**	**11.8945**	31.24%

Kết quả cho thấy RMSE của mô hình Hybrid đạt mức thấp nhất trong tất cả các phương pháp đã thử nghiệm (**17.2437**). Sự sụt giảm RMSE và MAE khẳng định rằng việc kết hợp khả năng mô hình hóa chuỗi thời gian thống kê với khả năng học máy phi tuyến tính giúp tăng độ ổn định cho dự báo nồng độ bụi PM2.5 trong môi trường đô thị phức tạp như TP. Hồ Chí Minh.

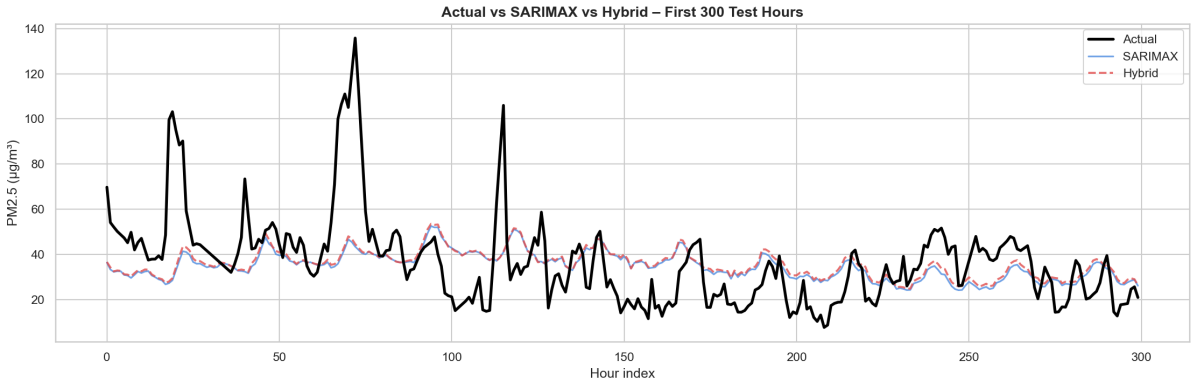

Figure 5.3: Kết quả dự báo của mô hình Hybrid so với thực tế trên tập Kiểm tra

5.3 Đối sánh tổng thể và Lựa chọn mô hình tối ưu

Sau khi thực hiện tinh chỉnh siêu tham số và thử nghiệm các cấu trúc kết hợp, nghiên cứu tiến hành hội tụ kết quả của các "nhà vô địch" đại diện cho từng nhóm mô hình chính: Cây quyết định (XGBoost), Thống kê (SARIMAX), Học sâu (Bi-GRU) và mô hình Kết hợp (Hybrid). Bảng 5.8 trình bày chi tiết các chỉ số hiệu năng trên tập Kiểm tra (Test set).

Table 5.8: Bảng đối sánh hiệu năng tổng thể các mô hình tối ưu

Nhóm	**Mô hình**	**RMSE**	**MAE**	**MAPE (%)**
Hybrid	**Hybrid (SARIMAX+GRU)**	**17.2437**	**11.8945**	31.24%
Stats	SARIMAX (Tuned)	17.3994	11.9630	30.98%
Tree	XGBoost (Tuned)	17.7965	12.7630	36.52%
DL	Bi-GRU (Tuned)	17.7992	12.1730	**30.41%**

5.3.1 Phân tích và Thảo luận

Dựa trên kết quả đối sánh tổng thể, có thể rút ra các nhận định quan trọng sau:

1. **Ưu thế của mô hình Hybrid:** Mô hình Hybrid dẫn đầu ở cả hai chỉ số RMSE và MAE. Việc giảm RMSE xuống mức **17.2437** là một cải thiện đáng kể, đặc biệt khi RMSE là chỉ số phạt nặng các sai số lớn - một yếu tố cực kỳ quan trọng trong cảnh báo ô nhiễm không khí.

2. **Tính ổn định của nhóm Học sâu:** Mặc dù Bi-GRU đứng thứ tư về RMSE, mô hình này lại đạt chỉ số MAPE tốt nhất (**30.41%**). Điều này cho thấy mạng Neural rất mạnh trong việc nắm bắt các xu hướng chung, nhưng có thể gặp khó khăn hơn mô hình thống kê trong việc bắt kịp các đỉnh chu kỳ cực ngắn của bụi mịn.

3. **Sự bền bỉ của mô hình Thống kê:** SARIMAX đơn lẻ vẫn cho kết quả cực kỳ ấn tượng, vượt qua cả các mô hình học máy phức tạp như XGBoost. Điều này khẳng định dữ liệu PM2.5 tại khu vực nghiên cứu có tính quy luật thời gian (auto-regressive) và tính mùa vụ (seasonality) rất mạnh mẽ.

5.3.2 Kết luận lựa chọn

Xét trên tính toàn diện của các chỉ số lỗi và khả năng đáp ứng yêu cầu thực tế của bài toán dự báo ô nhiễm, mô hình **Hybrid (SARIMAX+GRU)** được lựa chọn làm giải pháp tối ưu cho đề tài. Mô hình này không chỉ mang lại độ chính xác cao nhất về số học mà còn kế thừa được khả năng giải thích chu kỳ của SARIMAX và khả năng học sâu của GRU, tạo ra một hệ thống dự báo có độ tin cậy và tính linh hoạt cao.

5.4 Trực quan hóa kết quả dự báo (Visual Inspection)

Để có cái nhìn trực quan hơn về năng lực dự báo của các mô hình bên cạnh các con số định lượng, nghiên cứu tiến hành phân tích thông qua các biểu đồ đối sánh. Việc trực quan hóa giúp xác định xem mô hình có thực sự học được các đặc trưng của chuỗi thời gian hay chỉ đang dự báo các giá trị trung bình ổn định.

5.4.1 So sánh trực quan các chỉ số lỗi

Biểu đồ so sánh sai số (Hình 5.1) cho thấy sự vượt trội của mô hình Hybrid và SARIMAX trong việc giảm thiểu sai số dự báo trung hạn.

5.5 Giải thích mô hình và Phân tích sâu (Interpretation)

Để mô hình dự báo không chỉ là một cấu trúc "hộp đen" (black-box), nghiên cứu tiến hành phân tích độ quan trọng của các đặc trưng (*Feature Importance*) thông qua mô hình XGBoost đã tinh chỉnh. Kết quả này giúp xác định những yếu tố nào thực sự thúc đẩy sự biến động của nồng độ PM2.5 tại TP. Hồ Chí Minh.

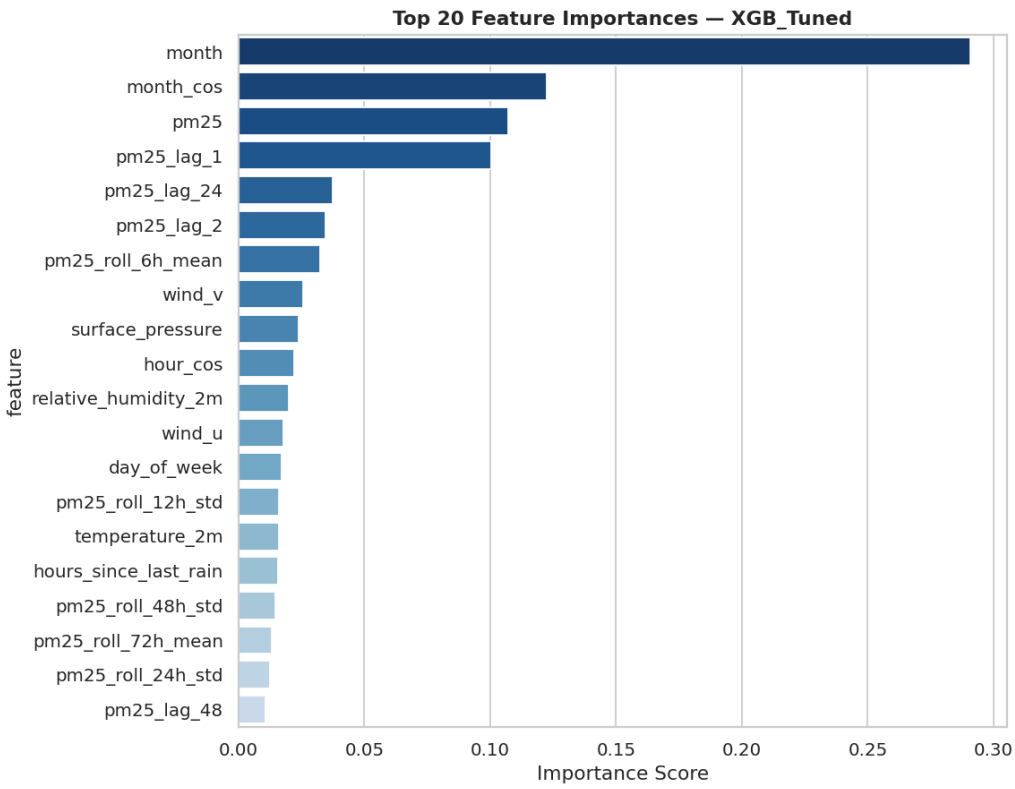

Figure 5.4: Top 20 đặc trưng có ảnh hưởng lớn nhất đến dự báo của mô hình XGBoost

5.5.1 Vai trò chủ đạo của tính mùa vụ (Seasonality)

Dựa trên Hình 5.4, đặc trưng `month` và `month_cos` đứng đầu về điểm số quan trọng. Điều này phản ánh sự tương quan chặt chẽ giữa chất lượng không khí và quy luật khí hậu nhiệt đới gió mùa tại TP. Hồ Chí Minh [12, 3]:

- **Mùa khô (Tháng 12 - Tháng 5):** Nồng độ bụi mịn thường ở mức cao do hiện tượng nghịch nhiệt vách biên và thiếu lượng mưa để rửa trôi (*wash-out*) các hạt bụi lơ lửng. Kết quả này đồng nhất với nghiên cứu của P. D. Hien và cộng sự [5], khẳng định nồng độ PM2.5 tại các đô thị Việt Nam có xu hướng tăng vọt trong những tháng mùa đông và đầu xuân.

- **Mùa mưa (Tháng 6 - Tháng 11):** Lượng mưa lớn giúp loại bỏ đáng kể PM2.5 khỏi khí quyển, đồng thời độ ẩm cao ngăn cản sự phát tán bụi từ mặt đất [9, 3].

Kết quả này hoàn toàn nhất quán với các nghiên cứu môi trường trước đây tại khu vực Đông Nam Á và miền Nam Việt Nam [3, 9], khẳng định rằng tính mùa vụ là biến số quan trọng nhất để thiết lập một khung dự báo dài hạn ổn định.

5.5.2 Tính bền vững và chu kỳ của ô nhiễm

Các đặc trưng tự hồi quy như `pm25`, `pm25_lag_1` và `pm25_lag_24` giữ vị trí cao trong bảng xếp hạng.

- **Lag 1 giờ:** Phản ánh tính "bền vững" (*Persistence*) của ô nhiễm không khí; nồng độ bụi tại một thời điểm phụ thuộc rất lớn vào trạng thái của giờ ngay trước đó [11, 1].

- **Lag 24 giờ:** Xác nhận chu kỳ sinh hoạt và giao thông hằng ngày. Các đỉnh ô nhiễm thường lặp lại vào các khung giờ cao điểm sáng và chiều khi lưu lượng phương tiện cơ giới đạt mức tối đa, một đặc điểm điển hình của các đô thị có mật độ giao thông cao như TP. Hồ Chí Minh [8, 3].

5.5.3 Ảnh hưởng của các yếu tố khí tượng

Các biến khí tượng như `wind_v` (gió hướng Bắc-Nam), `surface_pressure` (áp suất bề mặt) và `relative_humidity` (độ ẩm) đóng vai trò là các tác nhân điều tiết sự khuếch tán:

- **Gió:** Là phương tiện chính để di chuyển và pha loãng các khối khí ô nhiễm. Dinh và cộng sự [4] nhận định rằng tốc độ gió thấp tại HCMC vào các thời điểm chuyển mùa là nguyên nhân chính gây ra tình trạng ô nhiễm kéo dài.
- **Áp suất và Độ ẩm:** Áp suất cao thường đi đôi với bầu trời quang đãng nhưng khí quyển ổn định, làm hạn chế sự khuếch tán theo chiều đứng của bụi mịn [6, 3].

Chapter 6

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận chung

Đồ án "Phân tích và dự báo chất lượng không khí (PM2.5) tại TP. Hồ Chí Minh" đã hoàn thành các mục tiêu đặt ra, từ việc thu thập, xử lý dữ liệu đến việc xây dựng và tối ưu hóa các mô hình dự báo hiện đại. Dựa trên các kết quả thực nghiệm và phân tích chuyên sâu tại Chương 5, nghiên cứu rút ra các kết luận quan trọng sau:

1. **Về mặt kỹ thuật và mô hình hóa:** Dự án đã thực hiện so sánh đối sánh diện rộng giữa ba nhóm mô hình: Cây quyết định (Tree-based), Thống kê truyền thống (Econometrics) và Học sâu (Deep Learning). Kết quả cho thấy mô hình **Hybrid (SARIMAX-GRU)** đạt hiệu năng tối ưu nhất với chỉ số $RMSE = 17.2437$ và $MAE = 11.8945$. Việc kết hợp khả năng mô hình hóa thành phần tuyến tính, tính chu kỳ của SARIMAX với khả năng học sai số phi tuyến tính của mạng GRU đã tạo ra một hệ thống dự báo có độ chính xác và tính ổn định cao hơn so với việc sử dụng các mô hình đơn lẻ.

2. **Về các yếu tố tác động:** Thông qua việc phân tích độ quan trọng của đặc trưng (*Feature Importance*) và các kiểm định thống kê, nghiên cứu đã khẳng định nồng độ PM2.5 tại TP. Hồ Chí Minh chịu ảnh hưởng chi phối bởi **tính mùa vụ**. Sự khác biệt rõ rệt về chất lượng không khí giữa mùa khô (ô nhiễm cao do nghịch nhiệt) và mùa mưa (được cải thiện nhờ hiệu ứng rửa trôi) là quy luật quan trọng nhất cần lưu ý trong công tác quản lý môi trường đô thị.

3. **Về các quy luật thời gian:** Nghiên cứu đã xác nhận sự tồn tại của **chu kỳ sinh hoạt 24 giờ** liên quan mật thiết đến lưu lượng giao thông và hoạt động công nghiệp. Các đỉnh ô nhiễm thường xuất hiện vào khung giờ cao điểm sáng và chiều, chứng minh rằng phát thải từ phương tiện giao thông vẫn là nguồn đóng góp chính vào ô nhiễm bụi mịn tại khu vực nghiên cứu.

4. **Về tính ứng dụng:** Khung phương pháp luận (Framework) được đề xuất trong đồ án, bao gồm các bước từ tiền xử lý dữ liệu chuỗi thời gian, lựa chọn biến ngoại sinh đến tối ưu hóa mô hình kết hợp, hoàn toàn có thể được mở rộng để áp dụng cho các trạm quan trắc khác hoặc các loại chất ô nhiễm khác (như NO_2, SO_2). Kết quả dự báo có độ tin cậy cao của mô hình Hybrid cung cấp cơ sở khoa học quan trọng cho việc đưa ra các cảnh báo sớm về ô nhiễm, giúp người dân và các cơ quan chức năng có biện pháp ứng phó kịp thời.

Tóm lại, nghiên cứu đã thành công trong việc xây dựng một giải pháp dự báo PM2.5 có sự cân bằng giữa tính chính xác về mặt toán học và khả năng giải thích về mặt môi trường, đóng góp thiết thực vào nỗ lực giám sát và cải thiện chất lượng không khí tại TP. Hồ Chí Minh.

6.2 Hạn chế của đề tài

Mặc dù đã đạt được những kết quả khả quan trong việc dự báo nồng độ PM2.5, đề tài vẫn còn tồn tại một số hạn chế nhất định cần được nhìn nhận một cách khách quan:

- **Dữ liệu quan trắc còn giới hạn về không gian:** Nghiên cứu chủ yếu dựa trên dữ liệu từ một số trạm quan trắc cố định, do đó kết quả dự báo có thể chưa phản ánh hoàn toàn sự phân hóa nồng độ bụi mịn tại các khu vực đặc thù khác trong thành phố (như các khu dân cư gần khu công nghiệp hoặc các nút giao thông cục bộ có địa hình phức tạp).
- **Phạm vi các biến đầu vào:** Mô hình hiện tại tập trung chủ yếu vào các biến khí tượng và các giá trị trễ thời gian. Các yếu tố có tác động trực tiếp và biến động mạnh như lưu lượng giao thông thời gian thực, mật độ xây dựng và các sự cố môi trường đột xuất chưa được tích hợp trực tiếp vào mạng Neural do hạn chế về nguồn dữ liệu công khai.
- **Độ phức tạp tính toán:** Mô hình Hybrid (SARIMAX-GRU) tuy có độ chính xác cao nhưng đòi hỏi tài nguyên tính toán lớn hơn và thời gian huấn luyện lâu hơn so với các mô hình thống kê truyền thống. Điều này có thể gây ra thách thức khi cần triển khai hệ thống dự báo thời gian thực trên các thiết bị phần cứng có cấu hình hạn chế (Edge computing).
- **Hiện tượng trễ trong dự báo các đỉnh cực trị:** Mặc dù đã sử dụng cơ chế Bidirectional GRU để cải thiện, mô hình vẫn còn gặp khó khăn nhất định trong việc bắt kịp các thay đổi đột ngột của nồng độ bụi trong các tình huống thời tiết cực đoan (như bão hoặc thay đổi hướng gió đột ngột trong thời gian ngắn), dẫn đến sai số tại các điểm đỉnh (*peaks*) thường cao hơn mức trung bình.

6.3 Hướng phát triển tương lai

Để khắc phục các hạn chế hiện tại và mở rộng tính ứng dụng của đề tài, các hướng phát triển trong tương lai được đề xuất bao gồm:

- **Xây dựng mô hình không-thời gian (Spatiotemporal Modeling):** Mở rộng dữ liệu quan trắc sang mạng lưới nhiều trạm khác nhau và nghiên cứu áp dụng các kiến trúc mạng Neural đồ thị (Graph Neural Networks - GNN) để bắt được sự lan truyền ô nhiễm giữa các quận/huyện, cung cấp cái nhìn toàn diện hơn về bản đồ chất lượng không khí toàn thành phố.
- **Làm giàu dữ liệu đầu vào (Data Enrichment):** Tích hợp các nguồn dữ liệu đa dạng hơn vào mô hình dự báo như: lưu lượng giao thông thời gian thực từ API bản đồ, dữ liệu ảnh vệ tinh tầng thấp (Remote Sensing) và các chỉ số kinh tế - xã hội. Việc này sẽ giúp mô hình nhạy bén hơn với các biến động ngắn hạn do con người gây ra.

- **Ứng dụng các cơ chế tiên tiến như Attention và Transformer:** Nghiên cứu thay thế hoặc kết hợp khối GRU với cơ chế Attention (Chú ý) hoặc kiến trúc Transformer để cải thiện khả năng tập trung vào các sự cố ô nhiễm đột biến, từ đó giảm thiểu sai số tại các điểm cực trị.
- **Tối ưu hóa mô hình cho thiết bị cấu hình thấp:** Nghiên cứu các kỹ thuật nén mô hình (*Model Quantization*) hoặc kiến trúc mạng Neural nhẹ (như MobileNet cho dữ liệu chuỗi thời gian) để triển khai trực tiếp vào các trạm quan trắc IoT cầm tay, giúp phổ cập việc giám sát chất lượng không khí đến từng cá nhân.
- **Phát triển hệ thống cảnh báo sớm và Dashboard tương tác:** Xây dựng một nền tảng web/mobile tích hợp kết quả dự báo thực tế, cho phép người dân tra cứu nồng độ PM2.5 dự kiến trong 24-48 giờ tới, kèm theo các khuyến nghị sức khỏe và lộ trình di chuyển an toàn.

Tài liệu tham khảo

[1] Lorenzo Bermejo, Luis A Gil-Alana, and Marta del Rio. Time trends and persistence in pm2.5 in 20 megacities: evidence for the time period 2018–2020. *Environmental Science and Pollution Research*, 30(5):12933–12950, 2023.

[2] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, and Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. John Wiley & Sons, 5th edition, 2015.

[3] L. T. Bui, P. N. Hoang, and N. Duyen. Emission source areas of fine particulate matter (pm2.5) in ho chi minh city, vietnam. *Atmosphere*, 14(3):552, 2023.

[4] D. T. Dinh et al. Air quality in ho chi minh city, vietnam: A comparative study of recent ambient pm2.5 monitoring and satellite products. *Atmospheric Environment*, 243:117865, 2020.

[5] P. D. Hien et al. A comparative study of pm2.5 and pm10 in ho chi minh city and hanoi, vietnam. *Atmospheric Environment*, 36(15-16):2623–2635, 2002.

[6] D. J. Jacob and D. A. Winner. Effect of climate change on air quality. *Atmospheric Environment*, 43(1):51–63, 2009.

[7] T. T. Le et al. Pm2.5-bound polycyclic aromatic hydrocarbons in ho chi minh city, vietnam: Potential sources, health risks, and deposition flux. *Aerosol and Air Quality Research*, 24(3):230234, 2024.

[8] L. S. P. Nguyen et al. Current status of fine particulate matter (pm2.5) in vietnam's most populous city, ho chi minh city. *Aerosol and Air Quality Research*, 19(10):2239–2251, 2019.

[9] N. T. K. Oanh et al. Particulate matter pollution and its sources in southeast asia using model and monitoring approaches. *Atmospheric Environment*, 40(18):3367–3381, 2006.

[10] J. H. Seinfeld and S. N. Pandis. *Atmospheric chemistry and physics: from air pollution to climate change*. John Wiley & Sons, 2016.

[11] A. P. Tai, L. J. Mickley, and D. J. Jacob. Correlations between fine particulate matter (pm2.5) and meteorological variables in the united states: Implications for the sensitivity of pm2.5 to climate change. *Atmospheric Environment*, 44(32):3976–3984, 2010.

[12] T. H. To et al. Co-effects of covid-19 and meteorology on pm2.5 decrease in ho chi minh city, vietnam: A comparison of 2016–2019 and 2020–2021. *Aerosol and Air Quality Research*, 24(1):230182, 2024.